UNIVERSIDAD RAFAEL NÚÑEZ

Especialización en Analítica de Datos · Tecnologías de Procesamiento de Datos

Glosario Técnico

Docente: Heyder Medrano

Para qué sirve: Definiciones operativas de los términos que aparecen en las guías de preparación y en los talleres: lo que verás en pantalla y en los comandos.

Cómo usarlo: Los términos están agrupados por tema. La columna «Dónde aparece» indica en qué documento se usan.

Complementa: El glosario conceptual del Material de Apoyo del 30 de octubre (teorema CAP, consistencia, particionamiento, replicación).

Documentos: Preparación E1 = Preparación Previa del Encuentro 1 · Preparación E2 = Preparación Previa del Encuentro 2 · Taller Hadoop/Spark = Taller Local Hadoop y Spark · Taller BigQuery = Taller Cloud BigQuery · Taller Kafka = Taller Local Kafka y Spark Streaming.

1. Terminal y Windows

Término	Qué significa	Dónde aparece
PowerShell	Terminal de Windows donde se escriben los comandos. Se abre desde el menú Inicio escribiendo PowerShell.	Todos
Indicador (prompt)	Texto al inicio de cada línea de PowerShell, por ejemplo PS C:\tpd\hadoop>. Indica en qué carpeta estás; los comandos se ejecutan ahí.	Todos
Carpeta de trabajo (C:\tpd)	Carpeta con todos los archivos de los talleres: datos, hadoop, spark, bigquery y kafka. Se crea al copiar la carpeta tpd del material.	Preparación E1, talleres
Ruta	Dirección de un archivo o carpeta. En Windows usa barras invertidas (C:\tpd\datos); dentro de los contenedores, barras normales (/opt/datos).	Todos
cd	Cambia la carpeta actual (change directory). cd C:\tpd\datos entra a esa carpeta; cd .. sube un nivel.	Todos
dir	Lista los archivos y carpetas de la carpeta actual o de la ruta indicada.	Preparación E1
${PWD}	En PowerShell, la carpeta actual. Se usa para decirle a Docker qué carpeta compartir con el contenedor.	Preparación E1, Taller Hadoop/Spark
Script	Archivo con código que se ejecuta de una vez, por ejemplo preparar_dataset.py o producer.py.	Todos
pip / librería	pip instala librerías (paquetes de código reutilizable) de Python, como pandas, openpyxl o kafka-python.	Preparación E1, Preparación E2
Ctrl+C	Detiene el programa que está corriendo en la terminal.	Taller Hadoop/Spark, Taller Kafka
CSV	Archivo de texto con una fila por línea y columnas separadas por comas. Es el formato que leen Hadoop, Spark y BigQuery en los talleres.	Preparación E1, talleres

Término	Qué significa	Dónde aparece
UTC	Hora universal coordinada. Los contenedores usan esta hora: en Colombia es 5 horas más que la hora local.	Preparación E1

2. Docker

Término	Qué significa	Dónde aparece
Docker / Docker Desktop	Plataforma para ejecutar programas dentro de contenedores. Docker Desktop es la aplicación para Windows y Mac que incluye el motor y una interfaz gráfica.	Preparación E1
Motor (Engine)	El servicio de Docker que crea y ejecuta los contenedores. «Engine running» en Docker Desktop indica que está listo.	Preparación E1
WSL 2	Subsistema de Windows para Linux. Docker Desktop lo usa en Windows para ejecutar contenedores Linux.	Preparación E1
Imagen	Plantilla de solo lectura con un sistema y un programa ya instalados, por ejemplo apache/hadoop:3.4.3. Se descarga una vez y sirve para crear contenedores.	Preparación E1
Etiqueta (tag)	Versión de una imagen, lo que va después de los dos puntos: en spark:3.5.9-python3 la etiqueta es 3.5.9-python3.	Preparación E1
Capa (layer) y digest	Una imagen se descarga por partes (capas, cada una con su «Pull complete»). El digest (sha256:…) es su huella única.	Preparación E1
Docker Hub	Repositorio público de imágenes desde el que se descargan con docker pull.	Preparación E1
Contenedor	Instancia en ejecución de una imagen: un entorno aislado con su propio sistema de archivos y procesos, dentro de tu computador.	Todos
docker pull	Descarga una imagen desde Docker Hub.	Preparación E1, Preparación E2
docker run	Crea un contenedor a partir de una imagen y ejecuta un comando en él. --rm lo borra al terminar; -v comparte una carpeta; -w fija la carpeta de trabajo; -p publica un puerto; -it permite interactuar.	Preparación E1, Taller Hadoop/Spark
Montaje de carpeta (-v)	Hace que una carpeta de tu Windows aparezca dentro del contenedor. Ejemplo: C:\tpd se ve como /opt/tpd.	Preparación E1, Taller Hadoop/Spark
Puerto publicado	Puerto del contenedor accesible desde tu navegador en localhost, por ejemplo 9870 para la consola de HDFS.	Todos
localhost	Tu propio computador. http://localhost:8088 abre la página que publica un contenedor en el puerto 8088.	Todos
Docker Compose	Herramienta que levanta varios contenedores a la vez, descritos en un archivo docker-compose.yml.	Todos
docker-compose.yml	Archivo que define los servicios (contenedores), su imagen, puertos, carpetas compartidas y configuración.	Todos

Término	Qué significa	Dónde aparece
Servicio	Cada contenedor definido en el docker-compose.yml, por ejemplo namenode o kafka. Los comandos de Compose usan el nombre del servicio.	Todos
Proyecto de Compose	Conjunto de contenedores de un docker-compose.yml. Toma el nombre de la carpeta (hadoop, kafka) y lo usa como prefijo: hadoop-namenode-1.	Preparación E1
docker compose up -d	Crea y enciende los servicios en segundo plano (-d, detached).	Todos
docker compose ps / ps -a	Muestra el estado de los servicios. Con -a incluye los apagados.	Todos
docker compose exec	Ejecuta un comando dentro de un contenedor que ya está encendido.	Todos
docker compose stop / start	Apaga los contenedores conservando su contenido / los vuelve a encender.	Todos
docker compose down	Elimina los contenedores y su contenido (por ejemplo, lo guardado en HDFS). No se usa en los talleres.	Todos
docker compose logs	Muestra los mensajes de registro de un servicio; sirve para diagnosticar fallas.	Todos
Código de salida	Número entre paréntesis en «Exited (n)». 143 = apagado ordenado con stop; 1 = error de la aplicación; 137 = detenido por el sistema, casi siempre por falta de memoria.	Preparación E1
Red de Docker	Red interna que crea Compose para que los contenedores se hablen por su nombre (namenode, kafka) sin pasar por localhost.	Preparación E1, Preparación E2
Volumen con nombre	Almacenamiento administrado por Docker que sobrevive aunque se borre el contenedor. En Kafka guarda el conector de Spark descargado.	Preparación E2

3. Hadoop

Término	Qué significa	Dónde aparece
Hadoop	Plataforma de código abierto para almacenar y procesar grandes volúmenes de datos repartidos entre varias máquinas.	Preparación E1, Taller Hadoop/Spark
Modo pseudo-distribuido	Todos los componentes de Hadoop corren en un solo computador (aquí, cada uno en su contenedor), simulando un clúster.	Preparación E1, Taller Hadoop/Spark
HDFS	Sistema de archivos distribuido de Hadoop. Guarda los archivos divididos en bloques. No es tu disco C: se consulta con hdfs dfs.	Preparación E1, Taller Hadoop/Spark
NameNode	Componente de HDFS que guarda los metadatos: qué archivos hay y en qué DataNode está cada bloque. Consola web: localhost:9870.	Preparación E1, Taller Hadoop/Spark

Término	Qué significa	Dónde aparece
DataNode	Componente de HDFS que guarda los bloques de datos.	Preparación E1, Taller Hadoop/Spark
Bloque	Trozo en que HDFS divide un archivo (128 MB por defecto; en el taller se usan 32 MB). Cada bloque se procesa con un mapper.	Taller Hadoop/Spark
Factor de replicación	Cuántas copias de cada bloque guarda HDFS. Por defecto 3; en este clúster 1, porque hay un solo DataNode.	Preparación E1, Taller Hadoop/Spark
Modo seguro (safe mode)	Estado de solo lectura del NameNode al arrancar, hasta que los DataNodes reportan sus bloques. Sale solo en segundos.	Preparación E1
hdfs dfs	Comando para manejar archivos en HDFS: -mkdir crea carpetas, -put sube archivos, -ls lista, -cat muestra contenido.	Preparación E1, Taller Hadoop/Spark
hdfs fsck	Revisa la salud de un archivo en HDFS y muestra en cuántos bloques quedó dividido.	Taller Hadoop/Spark
YARN	Capa de Hadoop que administra la memoria y la CPU del clúster y reparte las tareas. Consola web: localhost:8088.	Preparación E1, Taller Hadoop/Spark
ResourceManager	Componente central de YARN: decide qué aplicación recibe qué recursos.	Preparación E1, Taller Hadoop/Spark
NodeManager	Componente de YARN en cada nodo: ejecuta las tareas. En el taller, el mapper y el reducer de Python corren aquí.	Preparación E1, Taller Hadoop/Spark
JobHistory Server	Servicio que guarda el detalle de los trabajos terminados (duración de cada tarea, contadores). Consola web: localhost:19888.	Preparación E1, Taller Hadoop/Spark
MapReduce	Modelo de procesamiento en dos fases, Map y Reduce, separadas por el shuffle.	Taller Hadoop/Spark
Mapper / reducer	El mapper procesa cada fila y emite pares clave-valor (país, cantidad); el reducer recibe todos los valores de una clave y los agrega (suma por país).	Taller Hadoop/Spark
Shuffle	Fase entre Map y Reduce que agrupa y ordena los pares por clave y los envía al reducer correspondiente. Suele ser la más costosa.	Taller Hadoop/Spark
Hadoop Streaming	Utilidad que permite escribir el mapper y el reducer en cualquier lenguaje (aquí Python), comunicándose por entrada y salida estándar.	Preparación E1, Taller Hadoop/Spark
Job / tarea (task)	Job: un trabajo completo enviado al clúster. Tarea: cada ejecución de un mapper o de un reducer dentro del job.	Taller Hadoop/Spark
Contadores (counters)	Estadísticas que Hadoop imprime al terminar un job: registros procesados, bytes del shuffle, tiempo de las tareas.	Taller Hadoop/Spark

4. Spark

Término	Qué significa	Dónde aparece
Spark	Motor de procesamiento distribuido que trabaja en memoria. Más rápido que MapReduce en tareas que reutilizan datos.	Preparación E1, Taller Hadoop/Spark, Taller Kafka
PySpark	La interfaz de Spark para Python. En los talleres ya viene dentro de la imagen spark:3.5.9-python3.	Preparación E1, Taller Hadoop/Spark
spark-submit	Programa que lanza un script en Spark.	Preparación E1, Taller Hadoop/Spark, Taller Kafka
SparkSession	Punto de entrada de un programa Spark: se crea al inicio del script y se cierra con spark.stop().	Preparación E1, Taller Hadoop/Spark
Modo local (local[*])	Spark corre en una sola máquina usando todos sus núcleos, sin clúster ni YARN.	Preparación E1, Taller Hadoop/Spark
DataFrame	Tabla distribuida con columnas con nombre y tipo, sobre la que se aplican operaciones como groupBy o agg.	Taller Hadoop/Spark
Evaluación perezosa (lazy)	Spark no ejecuta las transformaciones al escribirlas: arma un plan y lo ejecuta solo cuando una acción (show, count, write) pide un resultado.	Taller Hadoop/Spark
Job, stage y task (Spark)	Una acción genera un job; el job se divide en stages separados por shuffles; cada stage se ejecuta en tasks paralelas.	Taller Hadoop/Spark
DAG	Grafo dirigido acíclico: el plan de ejecución de un job, visible en la Spark UI.	Taller Hadoop/Spark
Spark UI	Consola web de Spark en localhost:4040. Solo existe mientras la sesión de Spark está abierta.	Taller Hadoop/Spark, Taller Kafka
Registros INFO / WARN	Mensajes que Spark imprime mientras trabaja. No son errores; los errores dicen ERROR o Exception.	Preparación E1, Taller Hadoop/Spark

5. Google Cloud y BigQuery

Término	Qué significa	Dónde aparece
Google Cloud	Plataforma de nube de Google. En los talleres solo se usa BigQuery.	Preparación E1, Taller BigQuery
Proyecto	Contenedor de recursos en Google Cloud (ej. tpd-bigquery). Todo lo que se crea en BigQuery pertenece a un proyecto.	Preparación E1, Taller BigQuery

Término	Qué significa	Dónde aparece
BigQuery / BigQuery Studio	Almacén de datos de Google Cloud que se consulta con SQL. BigQuery Studio es su interfaz en el navegador.	Preparación E1, Taller BigQuery
Sandbox	Modalidad gratuita de BigQuery sin tarjeta: 10 GB de almacenamiento, 1 TB de consultas al mes, tablas que vencen a los 60 días y sin INSERT, UPDATE ni DELETE.	Preparación E1, Taller BigQuery
Conjunto de datos (dataset)	Agrupación de tablas dentro de un proyecto. En el taller: taller_retail.	Taller BigQuery
Esquema	Lista de columnas de una tabla con su tipo (STRING, INTEGER, FLOAT, TIMESTAMP).	Taller BigQuery
Detección automática	Opción de BigQuery que adivina el esquema mirando las primeras filas. En el taller no se usa porque se equivoca con InvoiceNo y StockCode.	Taller BigQuery
Multirregión	Ubicación de los datos repartida en varias regiones de un área (ej. US).	Taller BigQuery
Bytes procesados	Datos que lee una consulta. Es la base del costo en BigQuery, que es columnar: cobra por las columnas leídas.	Taller BigQuery
Bytes facturados	Bytes que se cobrarían. Tienen un mínimo de 10 MB por consulta, por eso para comparar se usan los bytes procesados.	Taller BigQuery
Partición por rango entero	División de una tabla según un número (aquí anio_mes). Una consulta que filtra por esa columna solo lee las particiones necesarias.	Taller BigQuery
Clustering	Orden físico de los datos por una columna (aquí Country) que reduce lo leído cuando se filtra por ella.	Taller BigQuery
CREATE TABLE … AS SELECT	Crea una tabla nueva con el resultado de una consulta.	Taller BigQuery

6. Kafka y Spark Streaming

Término	Qué significa	Dónde aparece
Kafka	Plataforma para publicar y leer flujos de eventos en tiempo real. Guarda los mensajes durante un plazo (retención).	Preparación E2, Taller Kafka
ZooKeeper	Servicio que coordina el clúster de Kafka en la versión usada (Confluent 7.6).	Preparación E2, Taller Kafka
Broker	Cada servidor de Kafka. En los talleres hay uno.	Preparación E2, Taller Kafka
Topic	Canal con nombre donde se publican los mensajes, por ejemplo transacciones.	Preparación E2, Taller Kafka
Partición (Kafka)	División de un topic que permite leer en paralelo. Los mensajes con la misma clave van a la misma partición.	Taller Kafka
Líder y réplica	El líder de una partición atiende lecturas y escrituras; las réplicas son copias en otros brokers. Con un broker, todo tiene líder 1 y una sola copia.	Taller Kafka

Término	Qué significa	Dónde aparece
Offset	Posición de un mensaje dentro de una partición. Cada consumidor recuerda hasta qué offset leyó.	Taller Kafka
Productor / consumidor	El productor publica mensajes en un topic; el consumidor los lee.	Preparación E2, Taller Kafka
Grupo de consumidores	Consumidores que comparten el trabajo de leer un topic. Kafka guarda el offset de cada grupo.	Taller Kafka
LAG	Mensajes que un grupo aún no ha leído. LAG = 0 significa que está al día.	Taller Kafka
Retención	Tiempo o tamaño durante el que Kafka conserva los mensajes (por defecto, 7 días). Leer un mensaje no lo borra.	Taller Kafka
Listener / bootstrap server	Dirección por la que se conecta a Kafka: localhost:9092 desde Windows y kafka:29092 desde otros contenedores.	Preparación E2, Taller Kafka
Serializador	Función que convierte un mensaje (por ejemplo, un diccionario de Python) en bytes para enviarlo a Kafka; el deserializador hace lo contrario.	Taller Kafka
kafka-python	Librería de Python para crear productores y consumidores. Se usa la versión 2.3.2.	Preparación E2, Taller Kafka
Conector spark-sql-kafka	Paquete que permite a Spark leer y escribir en Kafka. Se descarga una vez desde Maven Central.	Preparación E2, Taller Kafka
Structured Streaming	Componente de Spark que procesa flujos de datos como una tabla que crece, en lotes pequeños.	Taller Kafka
Lote (batch / micro-batch)	Cada grupo de eventos que Spark procesa en una pasada. En la consola aparece como «Batch: N».	Taller Kafka
Ventana	Intervalo de tiempo sobre el que se agregan los eventos (aquí, 10 segundos).	Taller Kafka
Watermark	Límite de espera para eventos atrasados (aquí, 30 segundos). Pasado ese tiempo, Spark cierra la ventana y libera memoria.	Taller Kafka
Modo de salida (outputMode)	Qué resultados imprime Spark en cada lote. update: solo las ventanas que cambiaron.	Taller Kafka
Throughput / latencia	Throughput: eventos procesados por segundo. Latencia: tiempo que tarda un evento en ser procesado.	Taller Kafka

7. Dataset Online Retail II

Término	Qué significa	Dónde aparece
InvoiceNo	Número de factura. Si empieza con C, la factura es una cancelación.	Todos
StockCode / Description	Código y descripción del producto.	Todos
Quantity	Unidades vendidas en la línea. Es negativa en las cancelaciones.	Todos
InvoiceDate	Fecha y hora de la factura (formato 2010-12-01 08:26:00).	Todos
UnitPrice	Precio unitario en libras esterlinas.	Taller BigQuery

Término	Qué significa	Dónde aparece
CustomerID	Identificador del cliente. Puede estar vacío.	Todos
Country	País del cliente. Es la clave de agrupación en los tres talleres.	Todos