UNIVERSIDAD RAFAEL NÚÑEZ

Especialización en Analítica de Datos · Tecnologías de Procesamiento de Datos

Glosario Técnico

Docente: Heyder Medrano

Para qué sirve: Definiciones operativas de los términos que aparecen en la Preparación Previa, los talleres y el Proyecto Final: lo que verás en pantalla y en los comandos.

Cómo usarlo: Los términos están agrupados por tema. La columna «Dónde aparece» indica en qué documento se usan.

Complementa: La presentación del 30 de octubre (escalar, teorema CAP, consistencia, particionamiento, replicación, MapReduce, HDFS y YARN).

1. Codespace y terminal

Término	Qué significa	Dónde aparece
GitHub Codespaces	Servicio de GitHub que presta un computador en la nube y se usa desde el navegador. El del curso tiene 4 núcleos y 16 GB de memoria.	Todos
Codespace	Tu computador en la nube. Se crea una sola vez desde la plantilla del curso, queda en tu cuenta y conserva los datos y programas hasta que lo borres.	Todos
Plantilla (repositorio)	hmedrano-gif/tpd-codespace: los programas del curso. Al crear el codespace, GitHub copia la plantilla dentro de él; tu copia es tuya y la plantilla no cambia.	Preparación Previa
Horas de núcleo	Así cobra GitHub: cada hora encendido gasta 4 de las 120 gratis del mes (unas 30 horas de uso). Sin tarjeta, al acabarse no cobra: detiene el codespace.	Preparación Previa
Apagar el codespace	F1 → «Codespaces: Stop Current Codespace». Cerrar la pestaña no lo apaga; GitHub lo apaga solo a los 30 minutos sin actividad.	Todos
Terminal (bash)	La parte de abajo del codespace donde se escriben los comandos. Otra terminal se abre con Ctrl + Mayús + `.	Todos
Indicador (prompt)	Texto al inicio de cada línea de la terminal, por ejemplo @tu-usuario ➜ /workspaces/tpd-codespace/tpd/hadoop (main) $. Dice en qué carpeta estás; los comandos se ejecutan ahí.	Todos
Carpeta de trabajo	/workspaces/tpd-codespace/tpd: datos, hadoop, spark y kafka, con los programas del curso.	Todos
Ruta	Dirección de un archivo o carpeta, con barras normales: /workspaces/tpd-codespace/tpd/datos. Dentro de los contenedores, por ejemplo, /opt/datos.	Todos
cd	Cambia la carpeta actual (change directory). cd tpd/datos entra a esa carpeta; cd .. sube un nivel.	Todos
$PWD	La carpeta actual. Se usa para decirle a Docker qué carpeta compartir con el contenedor.	Taller 1A, Proyecto Final
Script	Archivo con código que se ejecuta de una vez, por ejemplo preparar_todo.sh, mapper.py o simulador.py.	Todos

Término	Qué significa	Dónde aparece
pip / librería	pip instala librerías (paquetes de código reutilizable) de Python, como pandas o kafka-python. En el codespace ya vienen instaladas.	Preparación Previa
Ctrl+C	Detiene el programa que está corriendo en la terminal y devuelve el indicador.	Taller 1A, Taller 1B
Puerto y dirección pública	Cada consola web atiende en un puerto (9870, 8088, 19888, 4040, 8501). GitHub la publica en https://<nombre-de-tu-codespace>-PUERTO.app.github.dev; localhost no abre desde tu navegador.	Taller 1A, Taller 1B
CSV y Parquet	CSV: texto con una fila por línea y columnas separadas por comas (4,04 GB el mes). Parquet: formato por columnas y comprimido (0,49 GB el mes); Spark lee solo las columnas que necesita.	Preparación Previa, Taller 1A
UTC	Hora universal coordinada. Los contenedores y las consolas usan esta hora: en Colombia son 5 horas menos.	Taller 1A

2. Docker

Término	Qué significa	Dónde aparece
Docker	Plataforma para ejecutar programas dentro de contenedores. En el codespace ya viene instalada y encendida.	Todos
Imagen	Plantilla de solo lectura con un sistema y un programa ya instalados, por ejemplo apache/hadoop:3.4.3. Se descarga una vez y sirve para crear contenedores.	Preparación Previa
Etiqueta (tag)	Versión de una imagen, lo que va después de los dos puntos: en spark:3.5.9-python3 la etiqueta es 3.5.9-python3.	Preparación Previa
Contenedor	Instancia en ejecución de una imagen: un entorno aislado con su propio sistema de archivos y procesos. Cada nodo de Hadoop y Kafka es un contenedor dentro de tu codespace.	Todos
docker run	Crea un contenedor a partir de una imagen y ejecuta un comando en él. --rm lo borra al terminar; -v comparte una carpeta; -w fija la carpeta de trabajo; -p publica un puerto; -it permite interactuar (por ejemplo, presionar Enter).	Taller 1A, Proyecto Final
Montaje de carpeta (-v)	Hace que una carpeta del codespace aparezca dentro del contenedor. Ejemplo: tpd se ve como /opt/tpd; tpd/hadoop como /opt/codigo.	Taller 1A, Proyecto Final
Docker Compose	Herramienta que enciende o apaga varios contenedores a la vez, descritos en un archivo docker-compose.yml (uno en hadoop y otro en kafka).	Todos
Servicio	Cada contenedor definido en el docker-compose.yml, por ejemplo namenode o kafka. Los comandos de Compose usan el nombre del servicio.	Todos
docker compose exec	Ejecuta un comando dentro de un contenedor que ya está encendido; con -T, sin abrir una terminal interactiva.	Todos
docker compose stop	Apaga los contenedores conservando su contenido: lo cargado en HDFS sigue ahí la próxima vez. Así se apaga Hadoop.	Taller 1A, Proyecto Final

Término	Qué significa	Dónde aparece
docker compose down	Elimina los contenedores y su contenido. Se usa para apagar Kafka, para que arranque limpio la próxima vez; nunca con Hadoop, porque borraría HDFS.	Taller 1B
encender_hadoop.sh / encender_kafka.sh	Scripts del curso que encienden Hadoop o Kafka y esperan a que estén listos («HADOOP LISTO», «KAFKA LISTO»).	Todos
Red de Docker	Red interna que crea Compose para que los contenedores se hablen por su nombre (namenode, kafka).	Taller 1A, Taller 1B

3. Hadoop

Término	Qué significa	Dónde aparece
Hadoop	Plataforma de código abierto para almacenar y procesar grandes volúmenes de datos repartidos entre varias máquinas.	Taller 1A
Modo pseudo-distribuido	Todos los componentes de Hadoop corren en un solo computador (aquí, cada uno en su contenedor), simulando un clúster. Es el mismo software de un clúster real.	Taller 1A
HDFS	Sistema de archivos distribuido de Hadoop. Guarda los archivos divididos en bloques. No es la carpeta del codespace: se consulta con hdfs dfs.	Taller 1A
NameNode	Componente de HDFS que guarda el índice: qué archivos hay y dónde está cada bloque. Consola web: puerto 9870.	Taller 1A
DataNode	Componente de HDFS que guarda los bloques de datos.	Taller 1A
Bloque	Trozo en que HDFS divide un archivo: 128 MB. El mes de viajes (4,04 GB) queda en 31 bloques; cada uno se procesa con una tarea map.	Taller 1A
Factor de replicación	Cuántas copias de cada bloque guarda HDFS. Por defecto 3; aquí 1, porque hay un solo DataNode.	Taller 1A
Modo seguro (safe mode)	Estado de solo lectura del NameNode al arrancar, hasta que los DataNodes reportan sus bloques. encender_hadoop.sh espera a que salga.	Taller 1A
hdfs dfs	Comando para manejar archivos en HDFS: -mkdir crea carpetas, -put sube archivos, -ls lista, -cat muestra contenido, -getmerge junta el resultado en un archivo.	Taller 1A, Proyecto Final
hdfs fsck	Revisa la salud de un archivo en HDFS y muestra en cuántos bloques quedó dividido (HEALTHY, 31 bloques).	Taller 1A
YARN	Capa de Hadoop que administra la memoria y la CPU y reparte las tareas. Consola web: puerto 8088. Con 4.096 MB caben 2 maps a la vez; con 6.144 MB, 4.	Taller 1A
ResourceManager / NodeManager	El ResourceManager decide qué aplicación recibe qué recursos; el NodeManager ejecuta las tareas (el mapper y el reducer de Python corren ahí).	Taller 1A
ApplicationMaster	Proceso que coordina un job dentro de YARN. Ocupa 2.048 MB de la memoria de YARN.	Taller 1A

Término	Qué significa	Dónde aparece
JobHistory Server	Guarda el detalle de los jobs terminados: Elapsed, tiempos promedio por fase y contadores. Consola web: puerto 19888.	Taller 1A
MapReduce	Modelo de procesamiento en dos fases, Map y Reduce, separadas por el shuffle.	Taller 1A
Mapper / reducer	El mapper convierte cada viaje en un par clave-valor (empresa → 1 viaje, tarifa, pago); el reducer suma todos los valores de cada clave.	Taller 1A, Proyecto Final
Shuffle	Fase entre Map y Reduce que agrupa y ordena los pares por clave y los envía al reducer. En el taller movió 370 MB sin combiner.	Taller 1A
Combiner	Suma parcial dentro de cada map antes del shuffle: el dato movido bajó de 370 MB a 2,3 KB con el mismo resultado.	Taller 1A, Proyecto Final
Hadoop Streaming	Utilidad que permite escribir el mapper y el reducer en cualquier lenguaje (aquí Python).	Taller 1A, Proyecto Final
Job / tarea (task)	Job: un trabajo completo enviado al clúster. Tarea: cada ejecución de un mapper o de un reducer dentro del job.	Taller 1A
Contadores (counters)	Estadísticas que Hadoop imprime al terminar un job: registros procesados, bytes del shuffle y contadores propios (por ejemplo, «Esperas negativas»).	Taller 1A

4. Spark

Término	Qué significa	Dónde aparece
Spark	Motor de procesamiento distribuido que trabaja en memoria. En el taller resolvió lo mismo que Hadoop en 78,8 s con CSV y 35,9 s con Parquet.	Taller 1A, Taller 1B, Proyecto Final
PySpark	La interfaz de Spark para Python. Ya viene dentro de la imagen spark:3.5.9-python3.	Taller 1A
spark-submit	Programa que lanza un script en Spark.	Taller 1A, Taller 1B, Proyecto Final
SparkSession	Punto de entrada de un programa Spark: se crea al inicio del script y se cierra con spark.stop().	Taller 1A
Modo local (local[*])	Spark corre en una sola máquina usando sus núcleos, sin clúster ni YARN. Con --nucleos N usa N núcleos.	Taller 1A, Proyecto Final
DataFrame	Tabla distribuida con columnas con nombre y tipo, sobre la que se aplican operaciones como groupBy o agg; equivale a una consulta SQL.	Taller 1A
Evaluación perezosa (lazy)	Spark arma un plan y lo ejecuta solo cuando una acción (show, count, write) pide un resultado; cada acción vuelve a leer los datos si no se guardan en caché.	Taller 1A
Job, stage y task (Spark)	Una acción genera un job; el job se divide en stages separados por shuffles; cada stage se ejecuta en tasks paralelas.	Taller 1A
DAG	Grafo dirigido acíclico: el plan de ejecución de un job, visible en la Spark UI. El recuadro «Exchange» es el shuffle.	Taller 1A

Término	Qué significa	Dónde aparece
Spark UI	Consola web de Spark en el puerto 4040. Solo existe mientras la sesión está abierta: por eso el programa espera Enter al final.	Taller 1A, Taller 1B
Registros INFO / WARN	Mensajes que Spark imprime mientras trabaja. No son errores; los errores dicen ERROR o Exception.	Taller 1A

5. Kafka y Spark Streaming

Término	Qué significa	Dónde aparece
Kafka	Plataforma para publicar y leer flujos de eventos en tiempo real. Guarda los mensajes durante un plazo (retención).	Taller 1B
ZooKeeper	Servicio que coordina el clúster de Kafka en la versión usada (Confluent 7.6).	Taller 1B
Broker	Cada servidor de Kafka. En el taller hay uno.	Taller 1B
Tema (topic)	Canal con nombre donde se publican los eventos: «viajes», con 2 particiones.	Taller 1B
Evento	Cada paso de un viaje publicado en Kafka: solicitud, asignado, llegada, recogida, fin_viaje y pago.	Taller 1B
Partición (Kafka)	División de un tema que permite leer en paralelo. Los eventos con la misma clave (el mismo viaje) van a la misma partición y en orden.	Taller 1B
Líder y réplica	El líder de una partición atiende lecturas y escrituras; las réplicas son copias en otros brokers. Con un broker, todo tiene líder 1 y una sola copia.	Taller 1B
Offset	Posición de un evento dentro de una partición. Cada grupo de consumidores recuerda hasta qué offset leyó.	Taller 1B
Productor / consumidor	El productor publica eventos en un tema (la app, el simulador); el consumidor los lee (la central, consumidor_consola.py, Spark).	Taller 1B
Grupo de consumidores	Consumidores que comparten el trabajo de leer un tema. Kafka guarda el offset de cada grupo: si se cae, al volver retoma donde quedó.	Taller 1B
LAG	Eventos que un grupo aún no ha leído. LAG = 0 significa que está al día; si crece sin parar, el consumidor no da abasto.	Taller 1B
Retención	Tiempo o tamaño durante el que Kafka conserva los mensajes (por defecto, 7 días). Leer un mensaje no lo borra.	Taller 1B
Bootstrap server	Dirección por la que se conecta a Kafka: localhost:9092 desde el codespace y kafka:29092 desde otros contenedores.	Taller 1B
kafka-python	Librería de Python para crear productores y consumidores. Se usa la versión 2.3.2.	Preparación Previa, Taller 1B
Conector spark-sql-kafka	Paquete que permite a Spark leer y escribir en Kafka. Se descarga una vez y queda guardado.	Preparación Previa, Taller 1B
Structured Streaming	Componente de Spark que procesa flujos de datos como una tabla que crece, en lotes pequeños.	Taller 1B

Término	Qué significa	Dónde aparece
Lote (micro-batch)	Cada grupo de eventos que Spark procesa en una pasada: uno cada 10 segundos. En la consola aparece como «=== Lote N».	Taller 1B
Ventana	Intervalo de tiempo sobre el que se agregan los eventos: 15 minutos.	Taller 1B
Watermark	Límite de espera para eventos atrasados: 30 minutos. Pasado ese tiempo, Spark cierra la ventana y libera memoria.	Taller 1B
Throughput / latencia	Throughput: eventos procesados por segundo (97 en el taller). Latencia: tiempo que tarda un evento en llegar al consumidor (2 ms).	Taller 1B

6. El caso: viajes de Uber y Lyft (TLC)

Término	Qué significa	Dónde aparece
TLC	Comisión de Taxis y Limusinas de Nueva York: publica cada mes los viajes de Uber y Lyft (High Volume FHV). El caso usa junio de 2025: 19.868.009 viajes.	Todos
hvfhs_license_num	Empresa del viaje: HV0003 = Uber, HV0005 = Lyft.	Todos
request / on_scene / pickup / dropoff_datetime	Hora en que el pasajero pide el viaje, llega el conductor, lo recoge y lo deja. La espera es pickup − request.	Taller 1A, Taller 1B
PULocationID / DOLocationID	Zona de recogida y de destino (265 zonas oficiales). Sus nombres y boroughs están en zonas.csv.	Todos
Borough	Cada uno de los cinco distritos de Nueva York: Manhattan, Brooklyn, Queens, Bronx y Staten Island.	Proyecto Final
trip_miles / trip_time	Distancia del viaje en millas y duración en segundos.	Proyecto Final
base_passenger_fare	Tarifa base que paga el pasajero, sin peajes, impuestos ni propinas.	Todos
driver_pay	Pago al conductor. La parte de la plataforma es (tarifa − pago) / tarifa.	Todos
tips / airport_fee / cbd_congestion_fee	Propina, cargo de aeropuerto y cargo de congestión de Manhattan (vigente desde enero de 2025).	Proyecto Final

7. Google Cloud y BigQuery (6 y 7 de noviembre)

Término	Qué significa	Dónde aparece
Google Cloud	Plataforma de nube de Google donde se trabaja el mismo caso el 6 y 7 de noviembre.	6 y 7 de noviembre
Proyecto	Contenedor de recursos en Google Cloud. Todo lo que se crea pertenece a un proyecto.	6 y 7 de noviembre
Dataproc	Servicio de Google Cloud que crea en minutos un clúster con Hadoop y Spark ya instalados; se paga solo mientras está encendido.	6 y 7 de noviembre

Término	Qué significa	Dónde aparece
BigQuery	Almacén de datos de Google Cloud que se consulta con SQL, sin clúster que configurar. Cobra por los datos que procesa cada consulta.	6 y 7 de noviembre
Sandbox	Modalidad gratuita de BigQuery sin tarjeta, con límites de almacenamiento y de consultas al mes.	6 y 7 de noviembre
Bytes procesados	Datos que lee una consulta. Es la base del costo en BigQuery, que es columnar: cobra por las columnas leídas.	6 y 7 de noviembre