UNIVERSIDAD RAFAEL NÚÑEZ

Especialización en Analítica de Datos · Tecnologías de Procesamiento de Datos

Hoja de ruta — Viernes 30 y sábado 31 de octubre

Docente: Heyder Medrano

Para qué sirve: Para no perderse: en cada parte, qué pregunta resolvemos, con qué herramienta, qué resultado deben ver y qué significa. Los comandos están en las guías de los talleres; aquí está el sentido.

El caso: Los 19.868.009 viajes de Uber y Lyft en Nueva York de junio de 2025 (TLC). La gerencia quiere saber cuánto se queda cada plataforma de lo que paga el pasajero, y qué pasa mientras los viajes ocurren.

Términos: si un término no te resulta claro, búscalo en Glosario_Tecnico_Tecnologias_Procesamiento_Datos.docx (carpeta Sesion_1_Vie_30_Octubre/Estudiantes).

La idea en tres frases

1. Cuando los datos crecen, un solo computador deja de alcanzar: no los abre, no le cabe en la memoria o tarda demasiado.

2. La solución es repartir: partir los datos en pedazos y procesarlos a la vez (Hadoop y Spark), o recibirlos uno por uno mientras ocurren (Kafka).

3. Este fin de semana usamos ese mismo software en una sola máquina, para entender cómo funciona y medirlo; el 6 y 7 de noviembre lo llevamos a la nube, con muchas máquinas.

Viernes 30 · Unidad 1: por qué repartir

Parte	Pregunta	Qué vemos	Qué significa
El problema	¿Qué pasa cuando los datos no caben?	Escalar hacia arriba (un computador más grande) o hacia los lados (más computadores).	Hacia arriba tiene un techo; hacia los lados se puede seguir creciendo.
Teorema CAP	Si la red falla, ¿qué prefiero?	Consistencia (todos ven el mismo dato) o disponibilidad (el sistema siempre responde).	No hay sistema perfecto: un banco elige consistencia, una red social disponibilidad.
Particionar y replicar	¿Y si se cae una máquina?	Los datos se reparten y se copian en varias máquinas.	Repartir da velocidad; copiar da seguridad.
MapReduce a mano	¿Cómo se suma algo repartido?	Con tarjetas de viajes reales: Uber US$ 292,61 y Lyft US$ 59,45; viajan 12 papeles, con combiner solo 6.	Mover datos cuesta; sumar antes de enviar ahorra.
HDFS y YARN	¿Quién guarda y quién reparte el trabajo?	HDFS guarda en bloques con copias; YARN asigna memoria y núcleos a cada tarea.	Son las dos piezas de Hadoop que mañana ven funcionar.

Antes de irse: crear la cuenta de GitHub (github.com/signup) y armar el grupo de 3 del Proyecto Final.

Sábado 31, mañana · Unidad 1 en la práctica (Taller 1A)

Parte	Pregunta	Herramienta	Resultado que deben ver	Qué significa
8:00	¿Tengo con qué trabajar?	Codespace	«RESULTADO: LISTO para el Taller 1»	Un computador en la nube con todo instalado.

Parte	Pregunta	Herramienta	Resultado que deben ver	Qué significa
Parte A	¿Basta un computador?	Excel y pandas	Excel no abre el mes; de la semana carga el 22,9 %. pandas pediría 10,8 GB.	Un análisis incompleto parece correcto y no avisa.
Parte B	¿Cuánto se queda cada plataforma?	Hadoop (MapReduce)	Uber 14.167.361 viajes y 23,3 %; Lyft 5.700.648 y 21,5 %.	La respuesta a la gerencia, con todos los viajes y exacta al centavo.
Parte B	¿Se puede hacer más barato?	Combiner y memoria de YARN	El dato movido baja de 370 MB a 2,3 KB; con más memoria, de 3:33 a 2:38.	Optimizar es mover menos y usar bien lo que hay.
Parte B	¿Dónde esperan más los pasajeros?	Su propio job	Flushing Meadows: 10,8 min. 231.332 viajes con datos errados.	Una pregunta nueva y un problema de calidad de datos.
Parte C	¿Hay una forma más rápida?	Spark	Mismo resultado: 78,8 s con CSV y 35,9 s con Parquet, leyendo 55 veces menos.	El formato de los datos cambia el tiempo y el costo.
11:00	¿Qué voy a resolver yo?	Proyecto Final	Cada grupo elige una de 8 preguntas.	Lo mismo de hoy, con otra pregunta del caso.

Sábado 31, tarde · Unidad 3: tiempo real (Taller 1B)

Parte	Pregunta	Herramienta	Resultado que deben ver	Qué significa
Paso 1	¿Cómo viaja un viaje?	App de viajes + Kafka	6 eventos, de la solicitud al pago.	Cada fila del archivo de la TLC nace de estos eventos.
Paso 3	¿Qué tan rápido?	Kafka	97 eventos por segundo, 2 milisegundos.	El dato está listo al instante, no al día siguiente.
Paso 4	¿Y si un programa se cae?	Kafka (offsets)	Al volver, retoma en el evento 210.	No se pierde ni se repite nada.
Paso 5	¿Llegó todo bien?	Verificador	«PRECISO»: 0 duplicados, montos al centavo.	Se puede confiar en el dato en tiempo real.
Paso 7	¿Qué pasa ahora mismo?	Spark Streaming	Espera por zona e ingresos cada 10 segundos.	La señal para subir el precio o mover conductores.

Si se pierden

Pregunten «¿qué pregunta estamos resolviendo en esta parte?» y busquen la fila en esta hoja. Los términos (bloque, shuffle, offset, partición…) están en el Glosario técnico, en la carpeta de la Sesión 1.