UNIVERSIDAD RAFAEL NÚÑEZ

Especialización en Analítica de Datos · Tecnologías de Procesamiento de Datos

Unidad 1: Fundamentos del Procesamiento Distribuido

Sesión 1 · Viernes 30 de octubre · 5:00–9:00 p. m.

Docente: Heyder Medrano

Tecnologías de Procesamiento de Datos

Especialización en Analítica de Datos · 3 créditos · 4 sesiones presenciales · Docente: Heyder Medrano

Sesión 1 · Vie 30 oct
5:00–9:00 p. m. · Unidad 1

Fundamentos del procesamiento distribuido: CAP, MapReduce, HDFS y YARN. Hoy.

Sesión 2 · Sáb 31 oct
8:00 a. m.–4:00 p. m. · Unidades 1 y 3

Taller 1A Hadoop y Spark con el mes completo; arranca el Proyecto Final; Taller 1B Kafka en tiempo real.

Sesión 3 · Vie 6 nov
5:00–9:00 p. m. · Unidad 2

La nube: AWS, Azure y Google Cloud, costos, seguridad y normativa; análisis de casos.

Sesión 4 · Sáb 7 nov
8:00 a. m.–4:00 p. m. · Unidades 2 y 3

Taller 2 en BigQuery y tablero; optimización; sustentaciones y examen práctico.

Evaluación

- Proyecto Final: diseño y configuración de un sistema distribuido · arranca sáb 31, se sustenta sáb 7
- Taller práctico: flujo de datos en tiempo real con Spark · sáb 31
- Análisis de casos: selección de tecnologías · vie 6, se sustenta sáb 7
- Simulación en la nube (Taller 2) y examen práctico · sáb 7

Lo que te llevas

- RA1 · Configurar Hadoop o Spark para procesar un mes completo
- RA2 · Seleccionar la nube adecuada con criterios de costo, seguridad y normativa
- RA3 · Desarrollar un flujo en tiempo real con Kafka que no pierde eventos
- RA4 · Ajustar memoria, núcleos y particiones y demostrarlo con mediciones

Un solo caso de principio a fin: 19,9 millones de viajes reales de Uber y Lyft en Nueva York. Cada sesión responde una parte de la misma pregunta de negocio.

Cómo vamos a trabajar: qué sí, qué no y por qué

En la empresa, el analista no construye la plataforma: la usa, la mide y decide con ella

Sí haremos	No haremos	Por qué
Ejecutar con el mes completo los procesos ya preparados	Instalar Hadoop, Spark o Kafka, ni montar servidores	En la empresa eso lo hacen ingeniería de datos o el proveedor de nube; el codespace ya lo trae listo
Configurar: cambiar memoria, núcleos o particiones y medir el efecto (RA1, RA4)	Configurar un clúster desde cero	Configurar, aquí, es ajustar un sistema que ya funciona y demostrar con mediciones que mejoró
Poner a andar el flujo en tiempo real con la app de viajes y comprobar que no pierde eventos (RA3)	Programar productores y consumidores desde cero	El analista necesita saber si el flujo es confiable y exacto, no escribir su código
Leer el código y explicar qué hace cada parte	Escribir o depurar programas	Basta entender cómo trabaja la herramienta para saber qué pedirle y qué esperar de ella
Consultar con SQL y armar el tablero (Spark, BigQuery, Looker Studio o Power BI)	Programar en Java o Scala	SQL y el tablero son las herramientas diarias del analista
Comparar tiempo, costo y exactitud, y recomendar una tecnología (RA2)	Memorizar comandos	Eso es lo que se evalúa: la decisión justificada con sus propias cifras

¿Y el tiempo? Las horas son las mismas: la máquina tarda lo mismo con o sin programar (cada job de Hadoop con el mes, 2,5 a 4,5 min). Lo que no se pierde corrigiendo código se usa en interpretar y decidir. Cada comando se copia de la guía, que muestra la salida esperada y qué hacer si algo falla.

Su papel es el de analista: lo que se evalúa es la decisión que toman con los datos, no escribir código.

Lo que necesitas para trabajar

Dónde está todo, qué se entrega y cómo cuidar el entorno

Materiales

Todo está en github.com/hmedrano-gif/CURN: una carpeta por sesión con la presentación, la guía del taller y los PDF. La presentación se abre con el enlace ▶ de cada carpeta.

Preparación Previa

Hoy, al cierre: crear tu cuenta de GitHub y verificar el correo (2 min). Mañana sábado a las 8:00 a. m., todos juntos: crear el codespace y pegar un comando hasta ver «LISTO para el Taller 1».

Bitácora

En cada taller anotan sus mediciones: tiempos, memoria, núcleos, eventos por segundo. Son la evidencia para comparar tecnologías y para sustentar.

Cuidar el codespace

La cuenta gratuita de GitHub trae horas limitadas al mes. Al terminar cada taller, detengan el codespace desde github.com/codespaces; encendido sigue gastando la cuota.

Proyecto Final

Diseñar y configurar un sistema distribuido que responda una pregunta del caso con el mes completo, y justificar la decisión con sus mediciones. Arranca el sábado 31 a las 11:00 y se sustenta el sábado 7.

Glosario técnico

En la carpeta de la Sesión 1: HDFS, YARN, shuffle, partición y los demás términos, explicados en lenguaje sencillo. Úsenlo cuando una palabra no les resulte clara.

Todo queda en GitHub: si alguien falta o se pierde, la carpeta de la sesión tiene lo necesario para ponerse al día.

El problema: lo que necesita saber la gerencia

Viajes de Uber y Lyft en Nueva York, junio de 2025 · datos abiertos de la Comisión de Taxis y Limusinas (TLC)

19.868.009	4,04 GB	≈ 662.000	71,3 % · 28,7 %
viajes en un mes	en CSV · 25 columnas por viaje	viajes por día	Uber · Lyft

Pregunta 1 · con el mes completo (por lotes)

¿Cuántos viajes hizo cada empresa, cuánto cobró de tarifa base, cuánto pagó a sus conductores y qué parte se quedó la plataforma?

Es la pregunta con la que Parrott y Reich (2018) sustentaron ante la TLC el pago mínimo para los conductores, vigente desde 2019.

Pregunta 2 · mientras ocurre (en tiempo real)

¿En qué zonas están esperando más los pasajeros y cuánto ingresa cada empresa, minuto a minuto?

Es la señal de una tarifa dinámica: si la espera sube en una zona, se sube el precio o se mueven conductores hacia allá.

El ejercicio de Tecnologías de Procesamiento de Datos: responder estas dos preguntas con el archivo real, completo y a tiempo. Ese es el problema; las tecnologías son la forma de resolverlo.

Por qué no se responde a tiempo, y cuánto cuesta

El negocio: US$ 556,9 millones de tarifa base en junio · US$ 127,0 millones retenidos por las plataformas (22,8 %)

Causa 1 · Volumen	Causa 2 · Velocidad	Causa 3 · Calidad	Causa 4 · Capacidad fija
Excel carga 1.048.576 filas: ve el 5,3 % del mes	Unos 460 viajes por minuto; el reporte nocturno llega tarde	231.332 esperas negativas y 12.901 tarifas en cero o menos	Un computador no crece con los datos; comprar para el pico deja equipos ociosos

US$ 12,2 M

en el mes, en 2.895.195 viajes (14,6 %) en los que el pago al conductor superó la tarifa base. ¿En qué zonas y a qué horas? Solo se sabe procesando el mes completo.

US$ 49,9 M

de tarifa en 1.482.132 viajes (7,5 %) con más de 10 minutos de espera. Los que cancelaron no aparecen en el archivo: esa pérdida solo se ve en tiempo real.

US$ 8,07 M

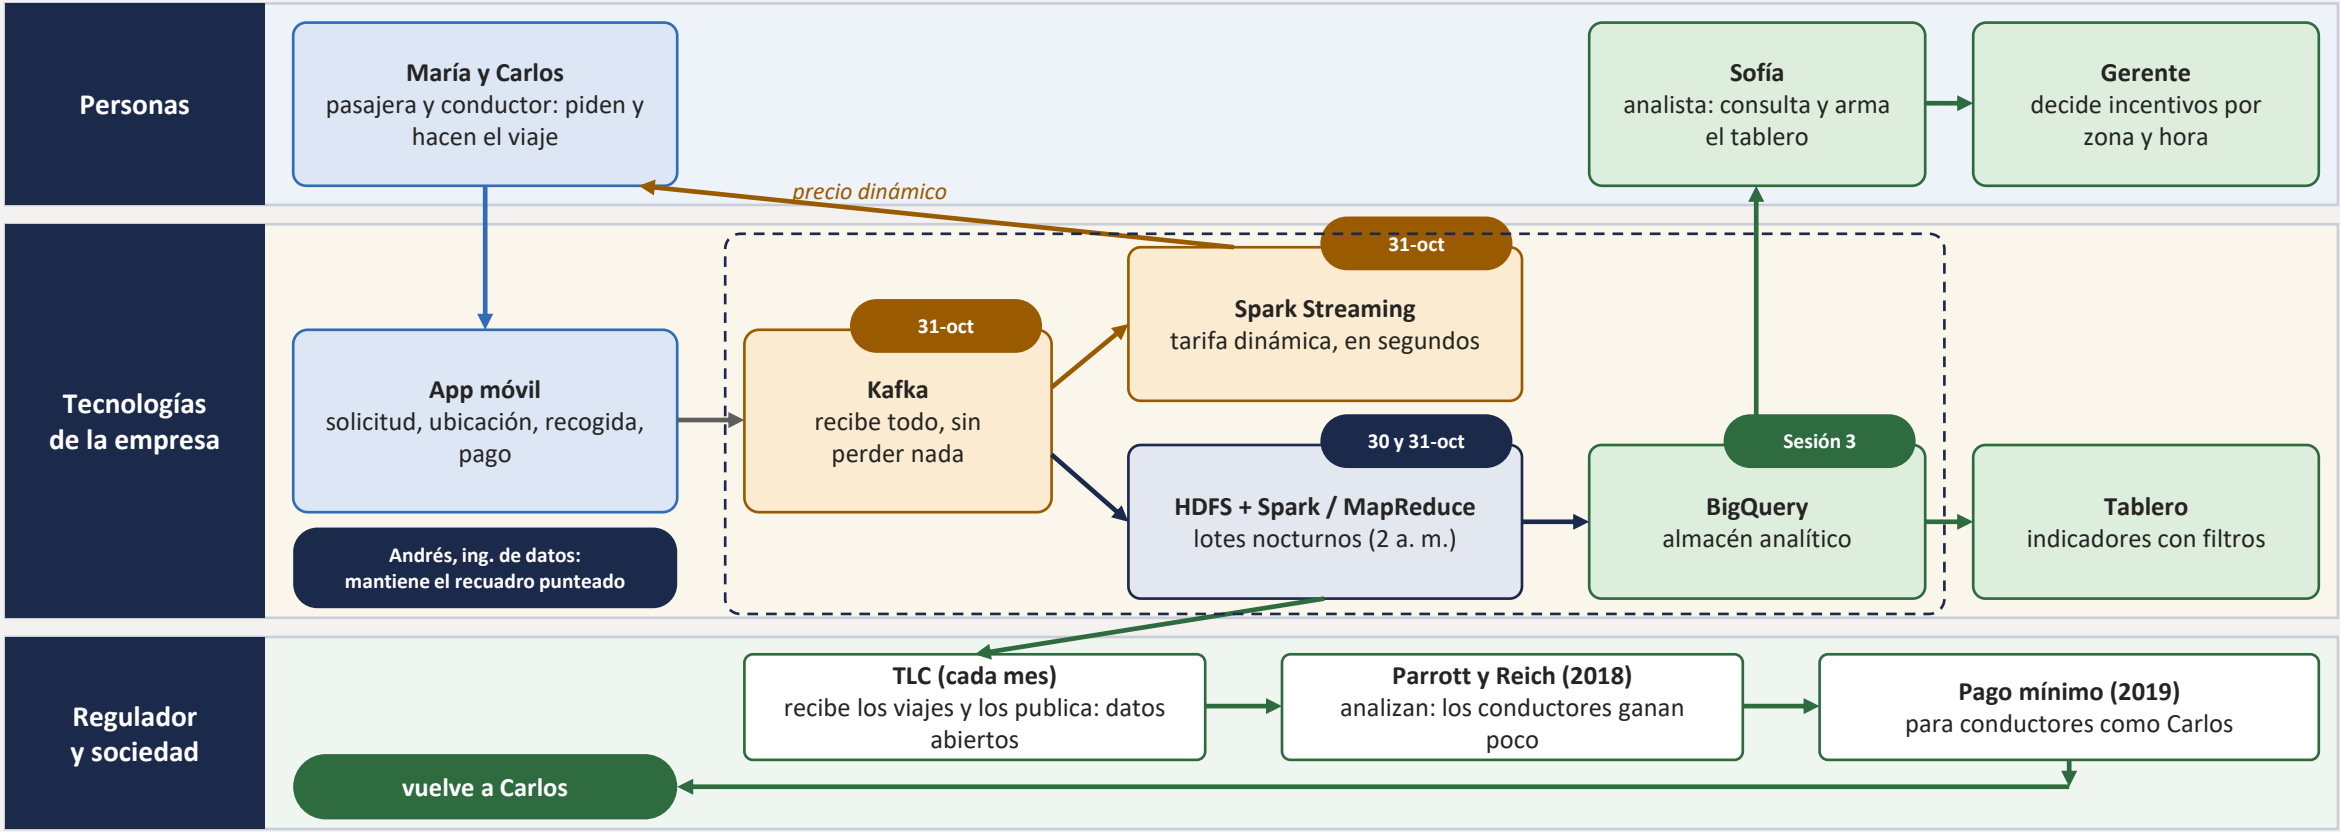
deja a las plataformas LaGuardia en un mes, la zona más rentable. Saber dónde se gana también es parte del problema.

Cifras del archivo completo de la TLC. Plataforma = tarifa base menos pago al conductor (sin peajes, impuestos ni propinas). «En riesgo» no es «perdido»: estimar cuánto se recupera es trabajo de analista.

Cada causa tiene una tecnología que la ataca: eso es lo que vamos a medir en estas 4 sesiones.

Una noche en Nueva York: la cadena de la información

Mapa de procesos del caso: quién genera cada dato, por dónde viaja y quién decide con él



En estas 4 sesiones seremos Andrés y Sofía: cada tecnología es un eslabón de esta cadena, y el archivo de la práctica es el que publica la TLC.

Personajes ilustrativos · tecnologías y hechos documentados: Fu y Soman (2021), TLC, Parrott y Reich (2018)

El objetivo del ejercicio: de la pregunta a la tecnología

Cada herramienta entra cuando la anterior se queda corta. Así se articula toda la asignatura

Excel y pandas	Hadoop	Spark	Kafka + Streaming	La nube
un solo computador	HDFS + YARN + MapReduce	en memoria, con SQL	eventos en tiempo real	BigQuery + tablero
Excel no abre el mes; pandas pediría unos 11 GB de memoria	Reparte el archivo en 31 bloques y el cálculo en 31 tareas	El mismo resultado, más rápido; lee directo el Parquet oficial	Responde la pregunta 2 mientras ocurren los viajes	Consulta el mes sin servidores propios y lleva la respuesta a la gerencia
Sáb 31 · Taller 1A · U1	**Sáb 31 · Taller 1A · U1**	**Sáb 31 · Taller 1A · U1**	**Sáb 31 · Taller 1B · U3**	**Sesión 3 · Taller 2 · U2**

Lo que el estudiante hace en cada paso, como analista que consume estas plataformas:

Mide: tiempo, datos leídos, datos movidos y costo

Compara: el mismo resultado con otra herramienta

Decide: qué tecnología responde cada pregunta y por qué

Objetivo: decidir con evidencia qué tecnología de procesamiento responde cada necesidad del negocio, completa, exacta y a tiempo.

¿Por qué hacerlo en la nube?

El analista no compra servidores: pide capacidad cuando la necesita y la devuelve cuando termina

Con el propio computador

- Hay que instalar y mantener todo: Docker, Hadoop, Spark, Kafka
- Cada equipo es distinto: lo que funciona en uno falla en otro
- La capacidad es fija: 8 o 16 GB no alcanzan cuando los datos crecen (un año del caso son unos 48 GB en CSV)
- Si el equipo falla o se apaga, se detiene el trabajo

En la nube

- Elasticidad: se piden 4 núcleos hoy y 400 mañana, por horas
- Pago por uso: se paga lo que se procesa (BigQuery cobra por los datos que lee cada consulta)
- Servicios administrados: el proveedor instala y opera; el analista consulta
- Desde el navegador: el mismo entorno para todos, en cualquier equipo

En esta asignatura:

Sesiones 1 y 2 · GitHub Codespaces: un computador en la nube de 4 núcleos y 16 GB, gratis y en el navegador, con Hadoop, Spark y Kafka

Sesiones 3 y 4 · Google Cloud: BigQuery consulta los 19,9 millones de viajes sin servidores propios y sin tarjeta (modo Sandbox)

La nube no siempre es la respuesta: datos sensibles con restricciones legales, o cargas constantes que salen más caras alquiladas que propias. Ese análisis (seguridad, normativa y costos) es la Unidad 2.

Agenda de hoy

Hoy, la Unidad 1 — mañana sábado 31, la práctica en GitHub Codespaces



Hoy, el marco para evaluar arquitecturas. Mañana, sábado 31-oct, en GitHub Codespaces: Hadoop y Spark (8:00 a. m.) y Kafka con la app de viajes (tarde).

Las herramientas de Tecnologías de Procesamiento de Datos

Qué usaremos, para qué y cuándo. Detalle: Preparación Previa (GitHub Codespaces)

Entorno de trabajo

Todas las sesiones

GitHub Codespaces

Computador en la nube (4 núcleos, 16 GB) desde el navegador

Docker

Ya viene en el codespace: Hadoop, Spark y Kafka en contenedores

Terminal (bash)

Para dar las órdenes, en la misma pestaña

Python

Preparar los datos; app de viajes y clientes de Kafka

Unidad 1 · Lotes

Sáb 31-oct, mañana

Hadoop: HDFS + YARN

Datos repartidos en bloques y recursos del clúster

MapReduce

Procesamiento por lotes en dos fases

Spark

El mismo cálculo en memoria, para comparar

Unidad 3 · Tiempo real

Sáb 31-oct, tarde

App de viajes (Streamlit)

Cliente, conductor y central publican cada evento del viaje

Kafka

Mueve eventos en tiempo real entre sistemas

Spark Structured Streaming

Procesa esos eventos en ventanas de tiempo

Unidad 2 · Nube

Sesiones 3 y 4

Spark en Google Cloud

Dataproc: demostración del docente

BigQuery

SQL sin servidores; costo por bytes procesados

Looker Studio

Tablero de indicadores para la gerencia

AWS y Azure

Comparativa de servicios; práctica opcional

También existen (solo para ubicarse, no se practican): Podman · Kubernetes · Cloudera · Amazon EMR · Azure HDInsight · Apache Flink · Databricks · Amazon Redshift · Azure Synapse · Snowflake · Apache Pulsar · Amazon Kinesis · Google Pub/Sub

Por qué estas herramientas

Criterios de elección. Lo que se aprende con ellas sirve con cualquier proveedor

1. **Lo pide el contenido programático**
2. **Sin costo: cuota gratuita de GitHub y BigQuery Sandbox, sin tarjeta**
3. **Corre igual para todos: en el navegador, sin instalar**
4. **Lo aprendido sirve con las alternativas**

Categoría	Usamos	Alternativa principal	Por qué la nuestra
Entorno	**GitHub Codespaces**	Docker Desktop en el PC	4 núcleos y 16 GB en el navegador; nadie instala nada
Contenedores	**Docker (en el codespace)**	Podman	Imágenes oficiales de Hadoop, Spark y Kafka
Terminal	**bash**	PowerShell	La terminal de los servidores Linux donde corren estas plataformas
Preparar datos	**Python + pandas**	Excel / Power Query	El dataset supera el máximo de filas de una hoja
Lotes distribuidos	**Apache Hadoop**	Amazon EMR	Gratis y muestra HDFS, YARN y MapReduce por separado
Motor en memoria	**Apache Spark**	Apache Flink	Un solo motor para lotes (U1) y tiempo real (U3)
Nube	**Google BigQuery**	Amazon Redshift	Muestra el costo de cada consulta; Sandbox sin tarjeta de respaldo
Tiempo real	**Apache Kafka**	Amazon Kinesis	Gratis; sus conceptos se usan en los servicios de nube

Bloque 1

Procesamiento distribuido y arquitecturas

5:30–6:30 p. m.

> *¿Qué pasa cuando una base de datos relacional ya no cabe en una sola máquina?*

Bloque 1 · Procesamiento distribuido

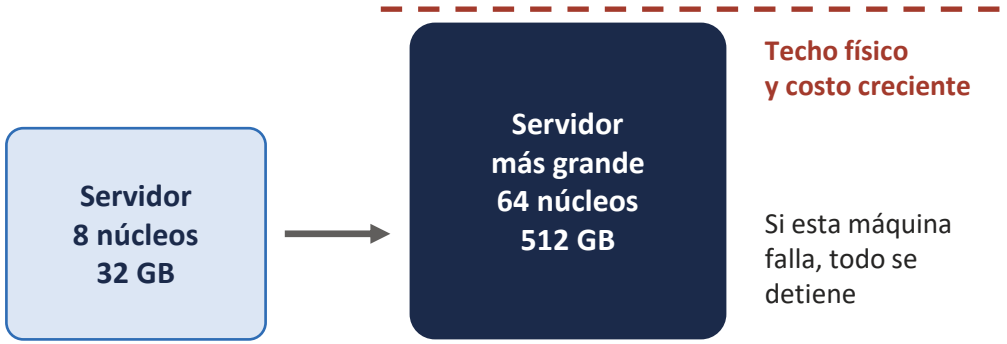
Bloque 2 · Modelo MapReduce

Bloque 3 · Ecosistema Hadoop

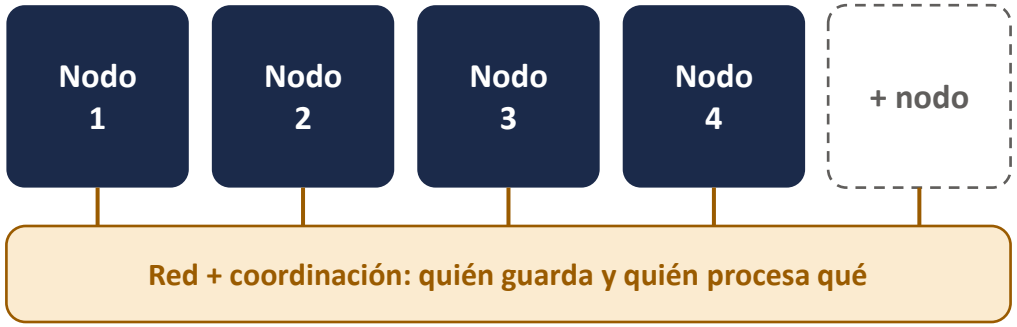
¿Qué pasa cuando una sola máquina no alcanza?

Cuando los datos crecen hay dos caminos: una máquina más grande o más máquinas trabajando juntas

Escalar verticalmente



Escalar horizontalmente



Crece agregando nodos comunes; si uno falla, los demás siguen.

- **Límite físico:** CPU, memoria y disco de una sola máquina son finitos.
- **Escalar verticalmente:** más potencia a la misma máquina. Simple, pero tiene techo y costo creciente.
- **Escalar horizontalmente:** más máquinas trabajando juntas. Sigue creciendo, pero exige coordinación.

Escenario: el cierre nocturno de viajes deja de caber

Cada noche se consolidan los millones de viajes del día. El volumen crece y el proceso ya no termina antes del amanecer.

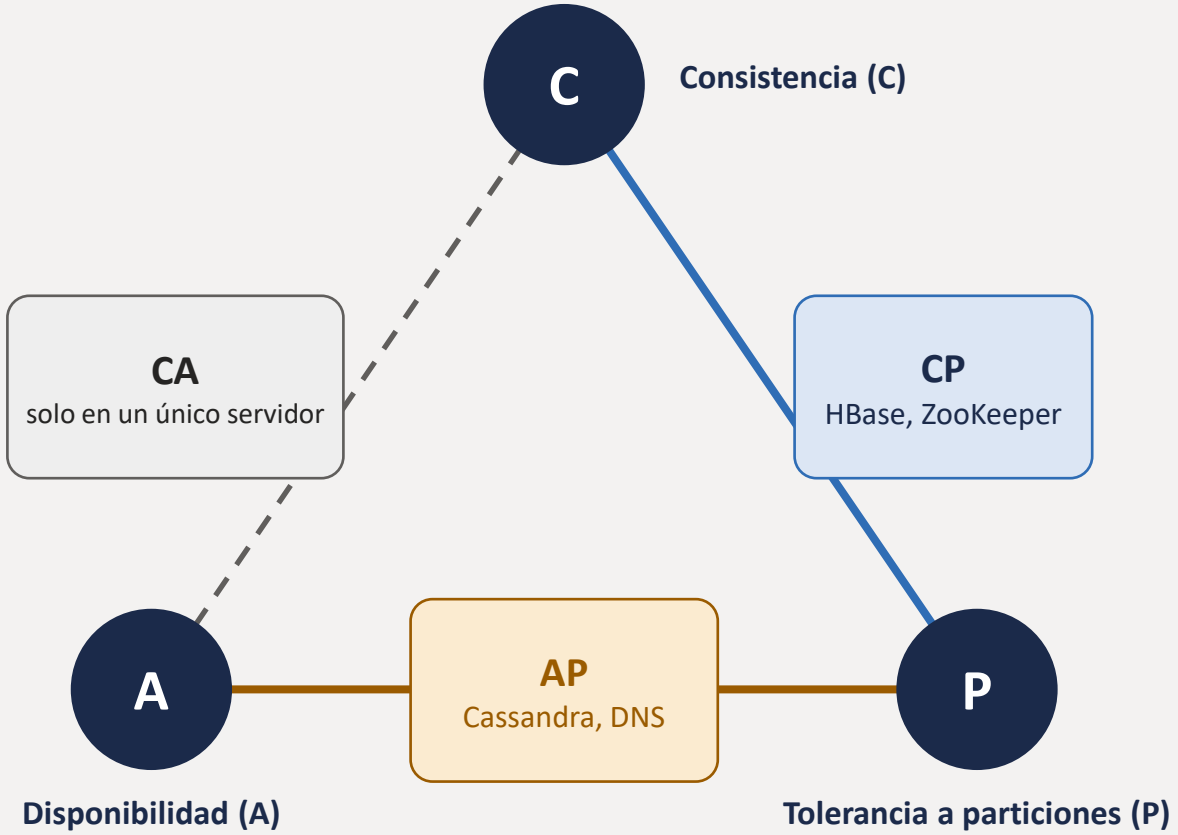
Camino vertical
Un servidor más grande: alcanza hasta el próximo techo y sigue siendo un único punto de falla.

Camino horizontal
Repartir los viajes entre varios nodos: se crece agregando nodos, pero hay que coordinarlos.

Escalar horizontalmente exige coordinación: esa coordinación es exactamente lo que estudia el procesamiento distribuido.

Teorema CAP

Si la red se parte, un sistema distribuido debe elegir: consistencia o disponibilidad



- **C:** toda lectura devuelve la escritura más reciente, sin importar qué nodo responda.
- **A:** todo nodo que funciona responde siempre, aunque otros nodos fallen.
- **P:** el sistema sigue operando aunque se pierdan mensajes entre nodos.

Escenario: la red se parte y alguien consulta un saldo

El nodo 1 registró un retiro; el nodo 2 no alcanzó a recibirlo. Un cliente consulta el saldo en el nodo 2.

Sistema CP
Responde «no disponible» o espera. Nunca entrega un saldo desactualizado.

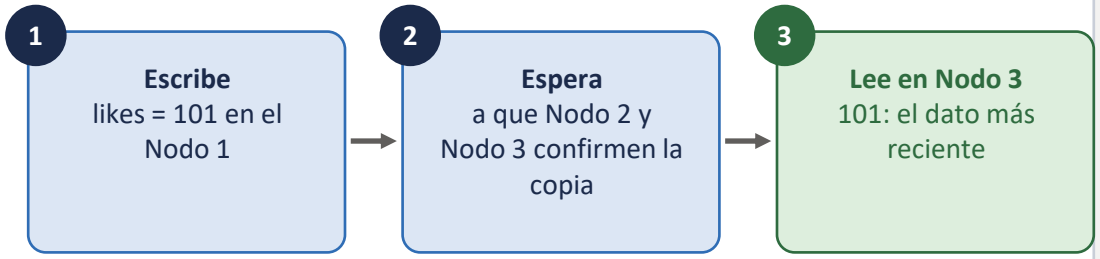
Sistema AP
Responde de inmediato, pero con el saldo anterior al retiro.

En un sistema distribuido real las particiones ocurren: P no se elige. La decisión es entre C y A, y es de negocio.

Consistencia fuerte vs. consistencia eventual

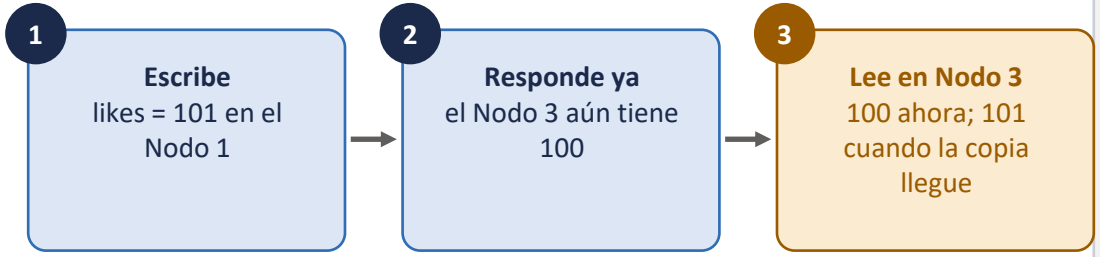
Qué ve quien lee justo después de una escritura, cuando el dato tiene tres réplicas

Consistencia fuerte



La escritura no termina hasta que las réplicas confirman: más espera, siempre correcta.

Consistencia eventual



Responde sin esperar: más disponible; las réplicas convergen después.

- **Consistencia fuerte:** toda lectura devuelve el dato más reciente. Más simple de razonar, más costosa de coordinar.
- **Consistencia eventual:** las réplicas convergen con el tiempo. Más disponible y escalable; exige diseñar la aplicación para tolerarlo.

Escenario: el mismo retraso, dos costos de negocio

Una réplica va un instante atrasada. ¿Cuánto cuesta que alguien lea el valor anterior?

Contador de «likes»
Ver 100 en vez de 101 por un instante no le cuesta nada a nadie: eventual basta.

Saldo bancario
Leer un saldo anterior al retiro permite gastar dos veces el mismo dinero: exige fuerte.

La elección no es solo técnica: depende del costo de negocio de un dato desactualizado.

Tolerancia a fallos y particionamiento

Particionar reparte la carga; replicar permite sobrevivir a la falla de un nodo

1. Particionar los viajes por distrito



2. Guardar cada partición en un nodo y su réplica en otro



Cae el Nodo 2: P2 se sigue leyendo desde su réplica en el Nodo 3, y P1 nunca dependió de él. Sin réplicas, los viajes de Brooklyn quedarían inaccesibles.

- **Particionamiento (sharding):** dividir los datos entre nodos para distribuir la carga.
- **Replicación:** mantener copias del mismo dato en varios nodos para sobrevivir a fallos.

Escenario: un nodo se apaga en plena consulta nocturna

Los viajes del caso están repartidos por distrito de recogida en 3 nodos, como en el diagrama.

Solo particionado
Los viajes del distrito de ese nodo quedan inaccesibles hasta que el nodo vuelva.

Particionado y replicado
La consulta sigue; el costo es guardar cada dato más de una vez y mantener las copias al día.

Todo diseño distribuido combina ambos, y cada combinación implica un trade-off distinto de costo, velocidad y riesgo.

Bloque 2

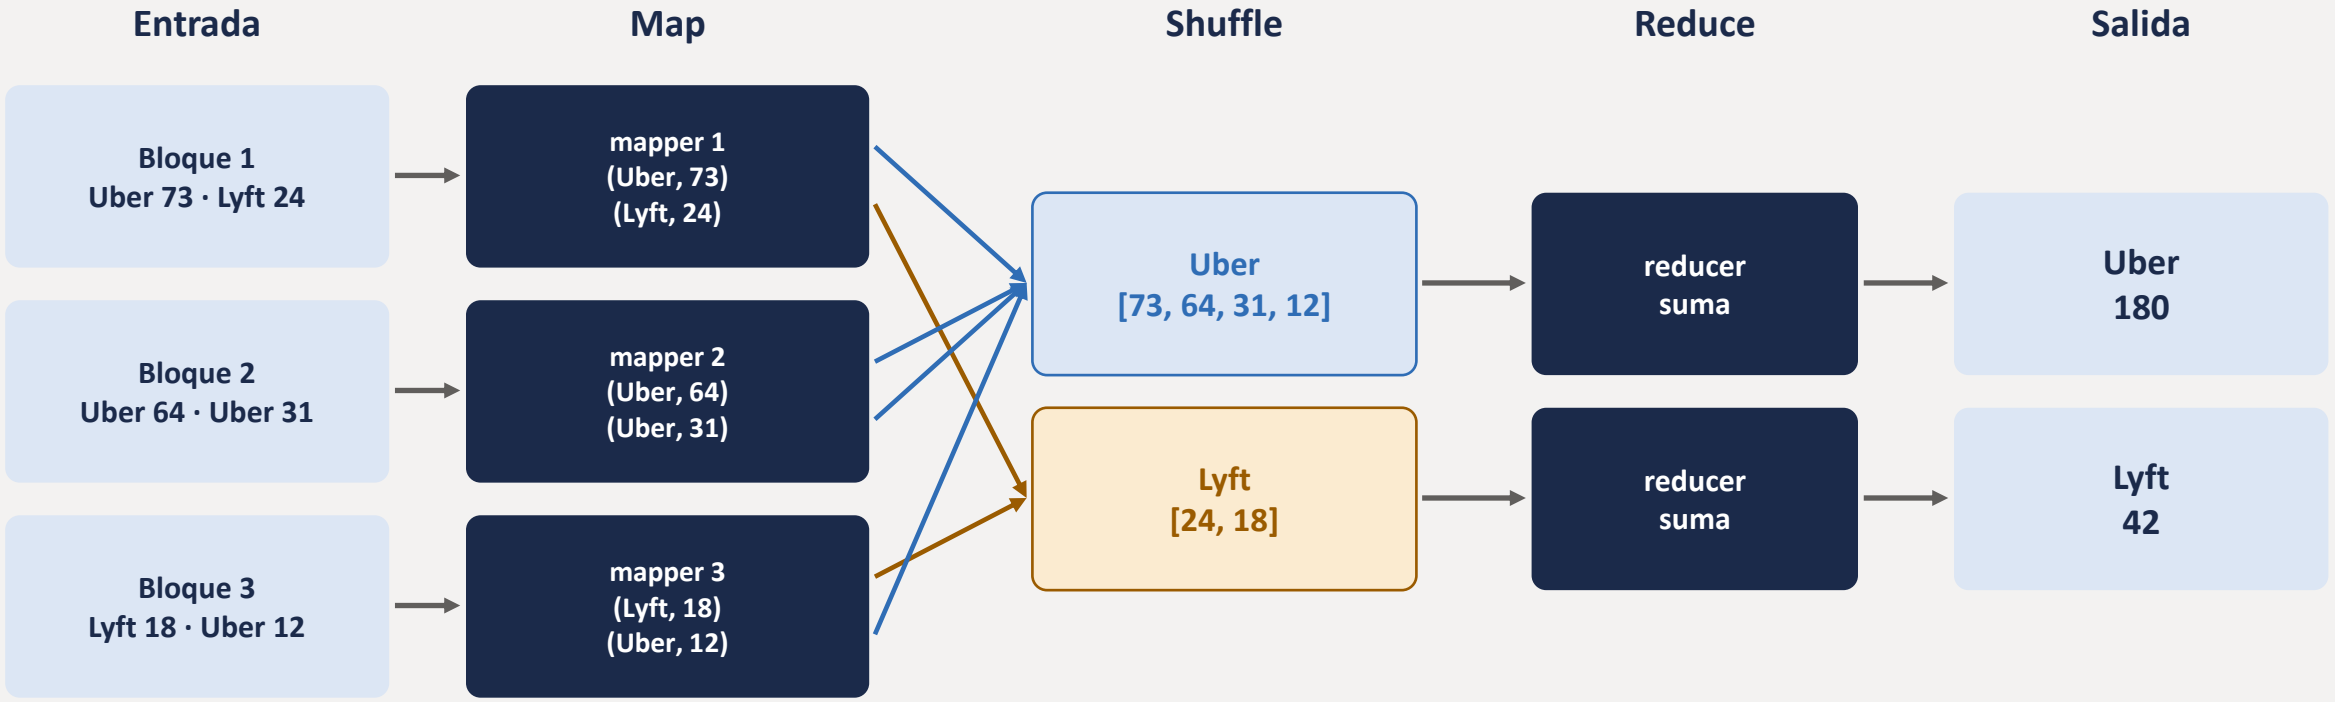
Modelo MapReduce

6:45–8:00 p. m.

> *¿Qué pasos de un problema de su trabajo serían «map» y cuáles «reduce»?*

Map → Shuffle → Reduce

El job del taller de mañana: tarifa base por empresa



Tarifas ilustrativas, en dólares. Las flechas de color son el shuffle: cada par viaja por la red al reducer de su clave.

Map
cada nodo procesa su porción de datos de forma independiente y en paralelo.

Shuffle
los resultados intermedios se agrupan por clave y se redistribuyen entre nodos.

Reduce
cada nodo agrega los valores de una clave y produce el resultado final.

El shuffle es la fase más costosa: mueve datos por la red entre todos los nodos.

Actividad: MapReduce a mano

15 minutos · 12 viajes reales del archivo de la TLC · grupos de estudiantes hacen de mappers y de reducers

Bloque 1 mapper 1	Uber US$ 73,25	Uber US$ 64,49	Lyft US$ 22,44	Uber US$ 32,99
Bloque 2 mapper 2	Uber US$ 57,12	Uber US$ 19,54	Lyft US$ 17,90	Uber US$ 8,84
Bloque 3 mapper 3	Uber US$ 8,38	Uber US$ 28,00	Lyft US$ 6,40	Lyft US$ 12,71

Tarifa base de cada viaje, en dólares. Una tarjeta por viaje.

1. Map: Cada grupo mapper escribe un papel por viaje: (empresa, tarifa).

2. Shuffle: Los papeles viajan: todos los de Uber al grupo reducer Uber y los de Lyft al grupo Lyft. Cuenten los papeles que viajaron.

3. Reduce: Cada reducer suma: Uber US$ 292,61 · Lyft US$ 59,45.

4. Combiner: Repitan sumando primero dentro de cada mapper: ¿cuántos papeles viajan ahora?

Sin combiner viajan 12 papeles; con combiner, 6 (dos por mapper). Con el mes completo: 19,9 millones de pares frente a 62.

Las limitaciones de MapReduce, no solo sus fortalezas

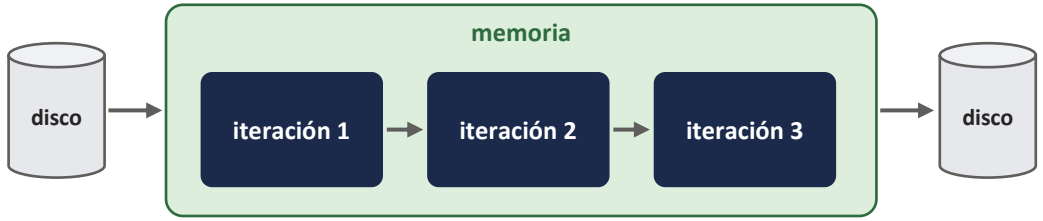
Un algoritmo iterativo repite el mismo cálculo varias veces sobre los mismos datos

MapReduce: cada iteración es un job nuevo



Cada iteración vuelve a leer del disco lo que escribió la anterior.

Spark: los datos quedan en memoria entre pasos



Lee una vez, itera en memoria y escribe el resultado al final.

- **Disco entre jobs:** cada job escribe los resultados intermedios a disco; costoso si el mismo dato se procesa varias veces.
- **Iterar es relanzar:** los algoritmos iterativos (p. ej., machine learning iterativo) relanzan el job en cada iteración.
- **Sin memoria compartida:** no hay forma nativa de mantener datos en memoria entre pasos de un mismo flujo.

Escenario: un modelo que se ajusta en 10 pasadas

El mismo cálculo recorre los viajes 10 veces, refinando el resultado en cada pasada.

Con MapReduce
10 jobs: cada uno arranca, lee del disco lo que dejó el anterior y vuelve a escribir.

Con Spark
Los viajes se leen una vez y las 10 pasadas trabajan sobre los datos en memoria.

Esta limitación concreta es la razón de ingeniería detrás de Apache Spark. Mañana la comprueban con métricas.

Bloque 3

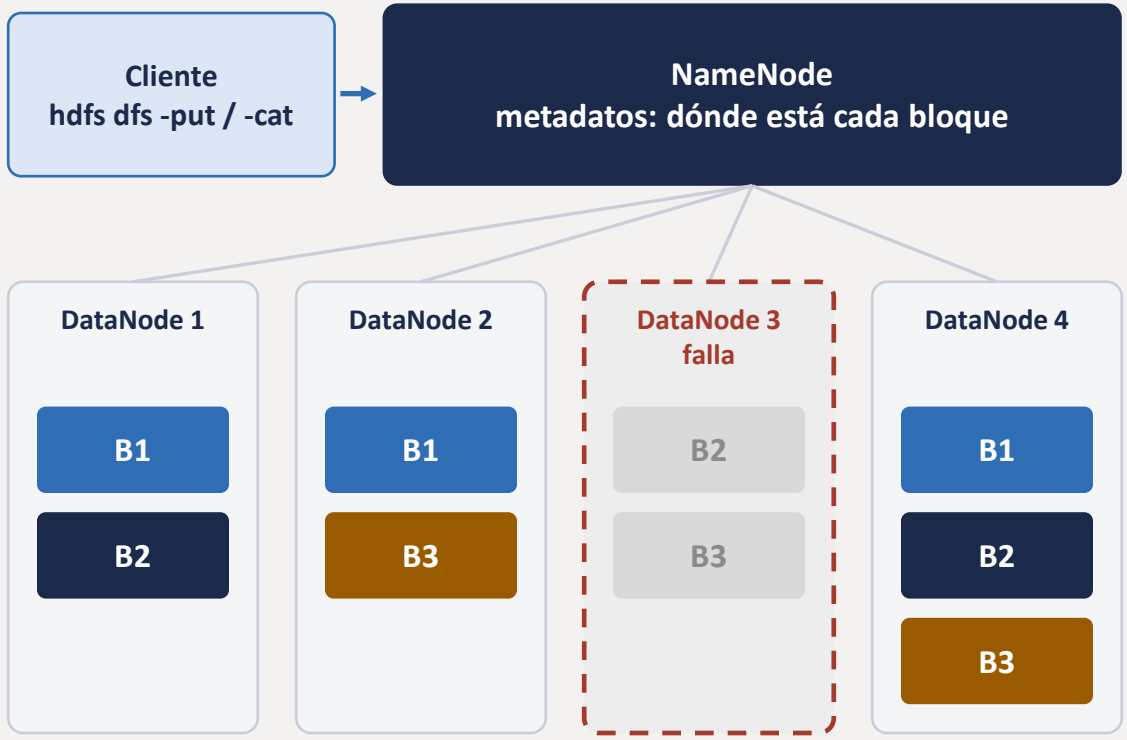
Ecosistema Apache Hadoop

8:00–9:00 p. m.

> *¿Por qué HDFS replica cada bloque 3 veces por defecto?*

HDFS: Hadoop Distributed File System

Un archivo se divide en bloques (B1, B2, B3) y cada bloque se guarda 3 veces en máquinas distintas



Cae el DataNode 3: B2 sigue en los DataNodes 1 y 4, y B3 en los DataNodes 2 y 4. Ningún dato se pierde.

- **NameNode:** mantiene los metadatos (qué bloque está en qué máquina); es el punto único de coordinación.
- **DataNodes:** almacenan los bloques reales de datos.
- **Réplicas:** cada bloque se replica 3 veces por defecto entre distintos DataNodes.

Escenario: se apaga una máquina del clúster

¿Qué pasa si la que se apaga es un DataNode? ¿Y si es el NameNode?

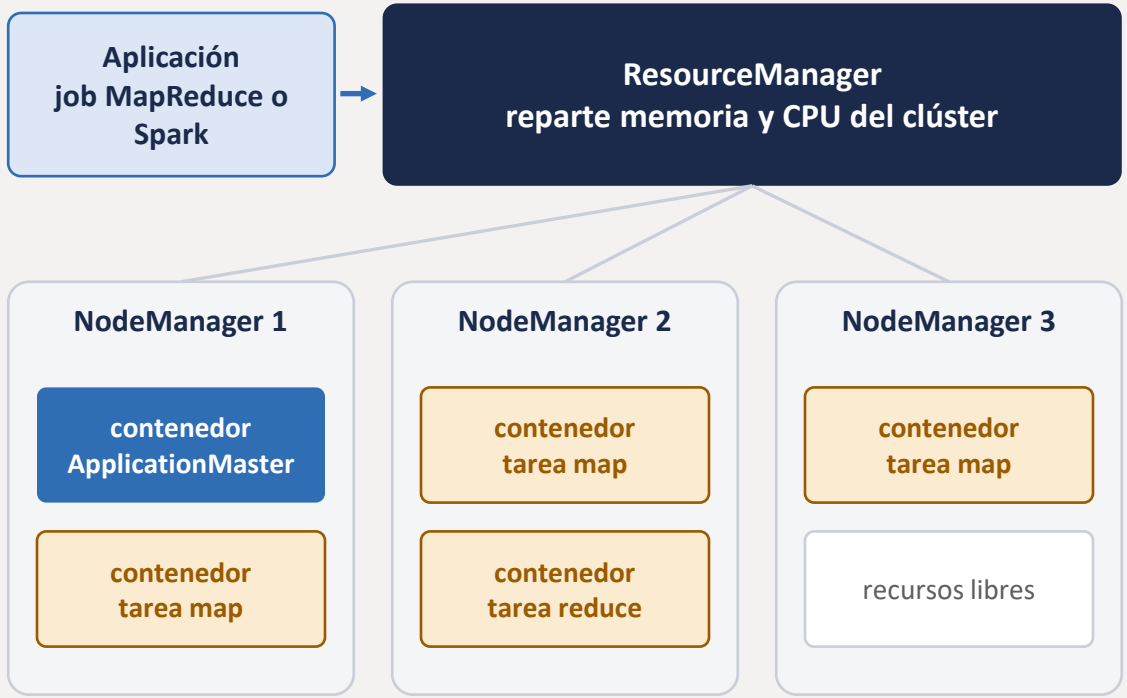
Cae un DataNode
Se leen las otras réplicas y el NameNode ordena recopiar los bloques hasta volver a 3.

Cae el NameNode
Los bloques siguen en disco, pero nadie sabe dónde está cada uno: HDFS se detiene.

El NameNode único es una decisión de diseño con una consecuencia clara: sin alta disponibilidad, es un punto único de falla.

YARN: gestión de recursos y scheduling

YARN reparte memoria y CPU del clúster en contenedores; cada aplicación coordina sus propias tareas



1. La aplicación se envía al ResourceManager.
2. El ResourceManager lanza el ApplicationMaster de esa aplicación en un contenedor.
3. El ApplicationMaster pide contenedores y lanza en ellos las tareas map y reduce.

- **Separación:** YARN gestiona los recursos; el modelo de procesamiento (MapReduce, Spark, etc.) va aparte.
- **ResourceManager:** decide qué aplicación recibe qué recursos del clúster.
- **NodeManager:** supervisa el uso de recursos en cada nodo individual.
- **ApplicationMaster:** uno por aplicación; pide contenedores y coordina sus tareas.

Escenario: dos motores en el mismo clúster

Un job MapReduce nocturno y un análisis con Spark llegan a la vez; YARN reparte el clúster entre ambos.

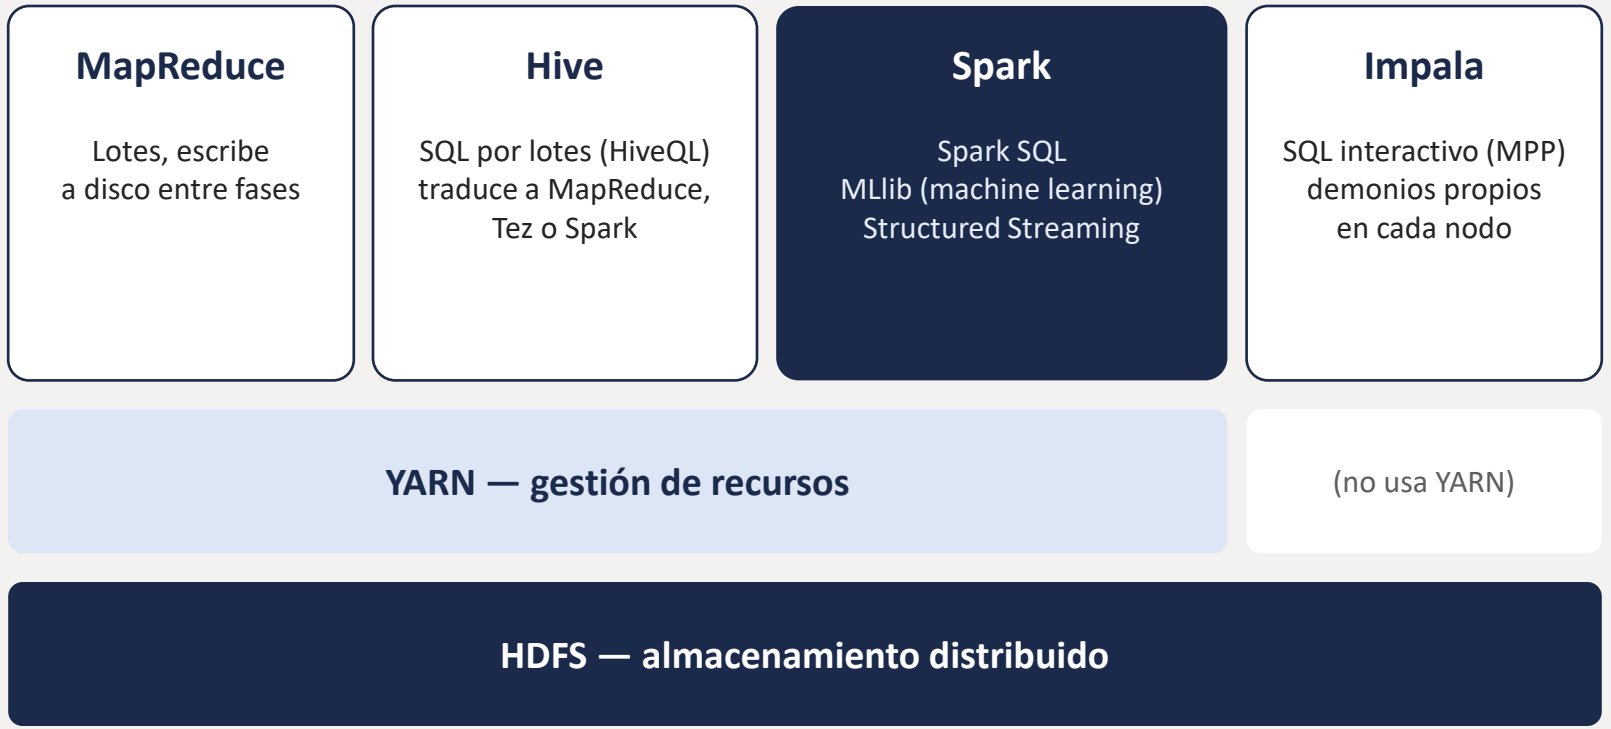
MapReduce
Su ApplicationMaster pide contenedores para map y reduce.

Spark
Su ApplicationMaster pide contenedores para sus ejecutores.

Esta separación es lo que permitió que Spark corriera sobre la misma infraestructura que Hadoop.

El ecosistema sobre HDFS y YARN

Informativo: herramientas que se apoyan en las capas vistas hoy (no se practican en el taller)



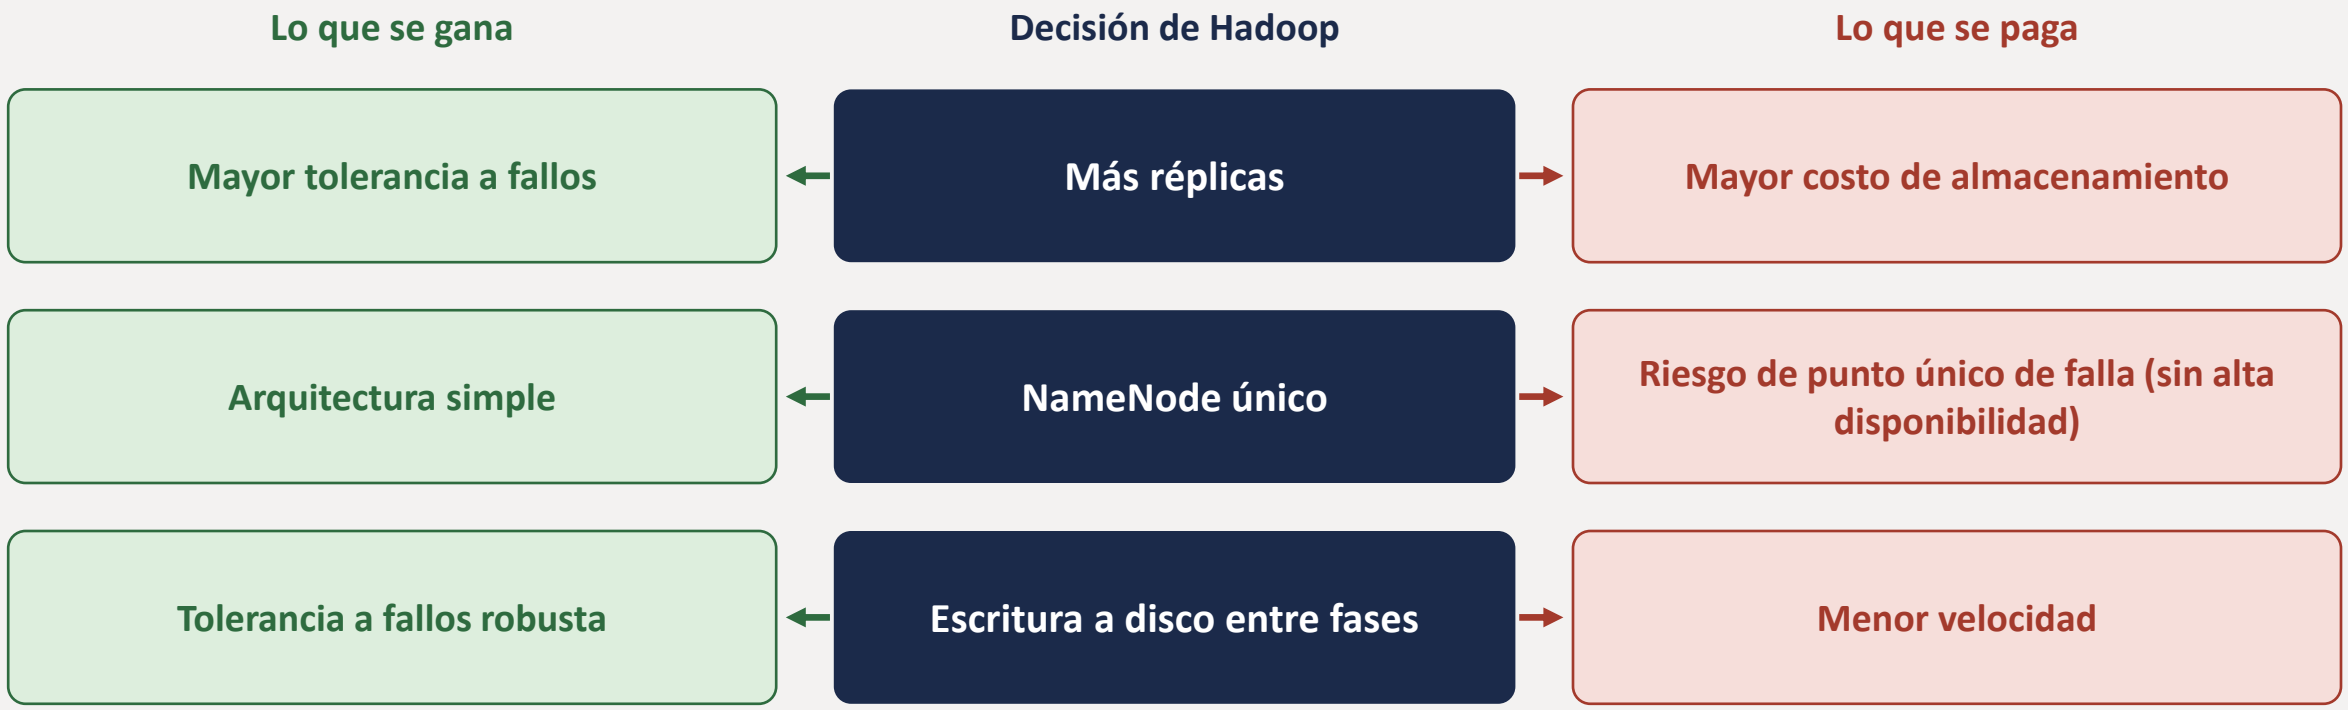
- **Hive:** tablas y SQL sobre archivos de HDFS. Pensado para lotes: cada consulta se vuelve un trabajo distribuido.
- **Impala:** SQL de baja latencia; ejecuta en memoria con sus propios procesos, sin pasar por MapReduce.
- **MLlib:** algoritmos de machine learning distribuidos en Spark. Los algoritmos iterativos aprovechan la memoria, justo la limitación de MapReduce que vimos hoy.

Spark también puede correr sin YARN (modo local o standalone): así lo usarán mañana, en su propio contenedor.

Idea para llevarse: el mismo HDFS sirve a motores distintos; elegir motor es elegir entre latencia, tipo de trabajo (lotes, interactivo, iterativo) y costo.

Trade-offs de diseño: no hay arquitectura gratuita

Cada decisión de Hadoop compra algo y lo paga con otra cosa



Cada decisión de Hadoop es defendible, y cada una tiene un costo que hay que poder justificar.

Cierre del día

Hoy

Escalar | Teorema CAP | Consistencia | Particionamiento y replicación | MapReduce | HDFS | YARN | Trade-offs

Mañana (sábado 31-oct, 8:00 a. m.)

1. **Preparación Previa todos juntos: crear el codespace y ver «LISTO»**
2. **Ejecutar y perfilar un job MapReduce real**
3. **Migrar a Spark y comparar**
4. **Arranca el Proyecto Final; en la tarde, Kafka y la app de viajes**

> *Antes de irse: creen su cuenta de GitHub en github.com/signup y verifiquen el correo. Mañana a las 8:00 a. m. creamos el codespace todos juntos. Armen hoy sus grupos de 3 del Proyecto Final.*