

hmedrano-gif.github.io/CURN/tpd/Sesion_3_Vie_6_Noviembre/

UNIVERSIDAD RAFAEL NÚÑEZ

Especialización en Analítica de Datos · Tecnologías de Procesamiento de Datos

De la nube a la decisión

Sesión 3 · 8 horas · Google Cloud, BigQuery y Power BI

Docente: Heyder Medrano Olier

> *El 31 de octubre el mes de junio necesitó un clúster en su codespace: 3 min 33 s en Hadoop y 36 s en Spark. Hoy cada grupo procesa SU mes en la nube, sin instalar nada y sin tarjeta, y lo lleva a Power BI.*

Unidad 2 · Procesamiento en la nube **Taller 2A · BigQuery** **Taller 2B · Power BI (página 1)**

Agenda

En la mañana la nube y BigQuery; en la tarde el modelo y el primer tablero en Power BI



8:10–9:15 · La nube

Qué es, quién administra qué, elasticidad, las tres nubes y Dataproc.

9:30–12:00 · Taller 2A

Su mes en BigQuery, las 8 preguntas en SQL y cuánto cuesta cada consulta.

1:00–2:05 · Modelo

Estrella, la trampa del promedio y Power BI conectado a BigQuery.

2:05–3:35 · Taller 2B

Medidas DAX y la página 1 del dashboard con su mes.

Cada bloque: yo lo hago en vivo con junio y luego cada grupo lo repite con su mes siguiendo el tutorial.

Palabras clave del día

Pulse una palabra para ver qué significa. Vuelva a esta diapositiva cada vez que aparezca una que no conozca

Nube · **Servidor** · **Máquina virtual** · **Clúster** · **Nodo maestro y trabajadores** · **IaaS, PaaS, SaaS** · **Sin servidor (serverless)** · **BigQuery** · **Conjunto de datos (dataset)**

Tabla · **Parquet** · **CSV** · **SQL** · **Consulta** · **MB, GB, TB** · **Zona de pruebas (sandbox)** · **Colab** · **Power BI** · **Modelo en estrella** · **Medida DAX** · **Conector**

Pulse una palabra

No hace falta memorizarlas: las verán usar durante el día y al final serán parte de su vocabulario.

¿Qué es la nube?

Según el NIST (National Institute of Standards and Technology, el instituto de normas técnicas de Estados Unidos): recursos de cómputo que se piden por internet, se comparten, crecen o se reducen y se cobran por uso

¿Dónde vive la nube? Tres modelos de despliegue

💡 **En palabras simples:** La nube es **alquilar en vez de comprar**: Google, Amazon o Microsoft tienen los computadores; usted los usa por internet y paga solo lo que gasta, como la luz o el agua.

Su codespace del sábado ya era nube: una máquina de GitHub que corre en Azure, pedida en minutos y apagada al terminar.

Fuentes: Mell y Grance (2011); UNIR, tema 8 (2026) · 📚 Bibliografía

¿Quién administra qué?

Pulse un modelo y mire qué capas pasan al proveedor (simulación)

Su empresa | **IaaS** | **PaaS** | **Sin servidor** | **SaaS** | **▶ Siguiente modelo**

Aplicación	usted
Datos	usted
Entorno de ejecución	usted
Sistema operativo	usted
Virtualización	usted
Servidores	usted
Red y almacenamiento	usted

Lo administra usted Lo administra el proveedor

Su empresa

Usted compra y mantiene todo: el servidor, el aire acondicionado y las actualizaciones.

Ejemplo: El computador del curso o el centro de datos propio (*on-premises*).

La regla

Mientras más capas administra el proveedor, menos instala usted y **más importa entender cómo cobra**.

💡 **En palabras simples:** Piense en una pizza: hacerla en casa (**su empresa**), comprar la masa lista (**IaaS**), pedirla a domicilio (**PaaS** o **sin servidor**) o comerla en el restaurante (**SaaS**). Mientras más hace el otro, menos trabaja usted.

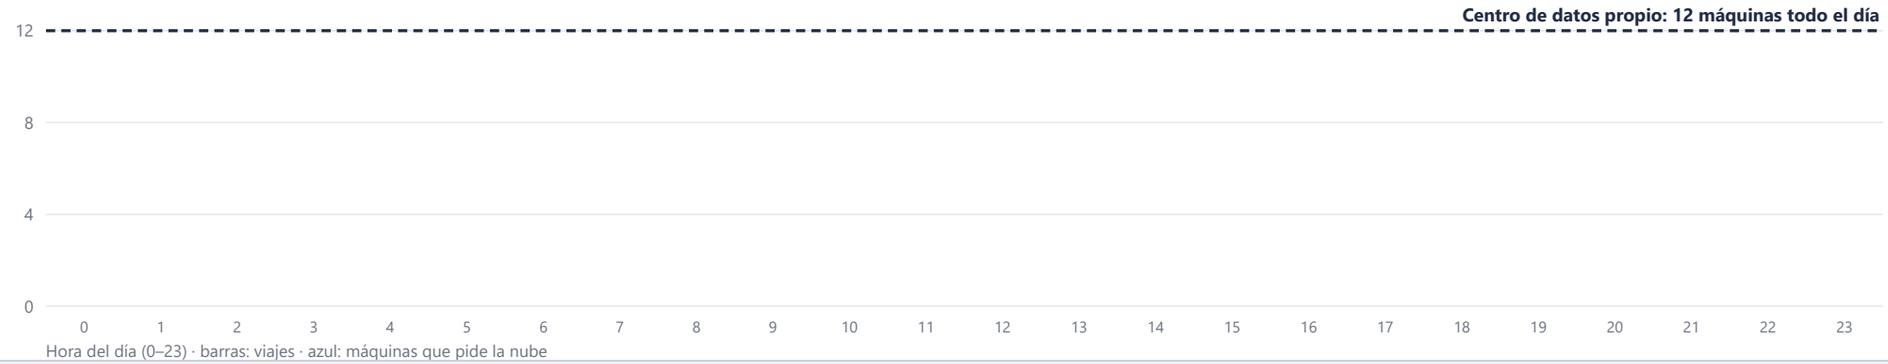
El sábado estuvimos en IaaS; hoy pasamos a «sin servidor». Es el mismo cálculo, pero sin administrar ninguna máquina.

Fuentes: Mell y Grance (2011); UNIR, tema 8 (2026) · 📚 Bibliografía

Elasticidad en vivo: un día de junio

Viajes reales de junio de 2025 por hora (suma del mes). Supuesto de la simulación: 1 máquina por cada 100.000 viajes de esa hora

▶ Simular el día Hora: —



Centro de datos propio
Hay que comprar para la hora pico
0
máquinas-hora pagadas

Nube elástica
Crece y se reduce cada hora
0
máquinas-hora pagadas

Capacidad ociosa
Pagada y sin usar
0 %

Hora pico
La hora con más viajes
6:00 p. m.
1.130.827 viajes

💡 **En palabras simples:** Elástica = como pedir carros por aplicación: no compra una flota para la hora pico; pide los que necesita en cada momento y los suelta cuando ya no los usa.

Elasticidad: no se compra para el peor momento, se paga lo que pide cada hora. Es la diferencia entre gasto de capital (comprar servidores) y gasto de operación (pagar por uso).

Fuentes: TLC (2025), cálculo del docente con la pregunta 1; UNIR, tema 8 (2026) · 📚 Bibliografía

AWS, Google Cloud y Azure frente a frente

*El mismo trabajo del curso en cada proveedor. Pulse un logo para resaltar su columna y **pulse un servicio para ver qué es***

Lo que hicimos en el curso	AWS	Google Cloud	Azure
Máquinas virtuales (IaaS)	EC2 (Elastic Compute Cloud)	Compute Engine	Azure Virtual Machines
Guardar archivos grandes (como HDFS)	S3 (Simple Storage Service)	Cloud Storage	Blob Storage · Data Lake Storage
Clúster Hadoop / Spark administrado (PaaS)	EMR (Elastic MapReduce)	Dataproc	HDInsight
SQL sin servidor sobre datos masivos	Athena · Redshift	**BigQuery**	Synapse Analytics
Mensajes en tiempo real (como Kafka)	MSK (Kafka administrado) · Kinesis	Pub/Sub	Event Hubs
Tablero	QuickSight	Looker Studio	Power BI
Uso gratuito para la clase	AWS Academy (por la institución)	**Zona de pruebas, sin tarjeta**	Azure for Students

Pulse cualquier servicio de la tabla y aquí aparece qué es y para qué sirve.

💡 **En palabras simples:** Las tres empresas venden **lo mismo con distintos nombres**. Lo que aprendan hoy con Google sirve para Amazon y Microsoft.

En el análisis de casos, cada grupo elige proveedor para su empresa con una matriz de costo, servicios, seguridad y equipo disponible.

Fuentes: UNIR, temas 8 a 10 (2026); Google Cloud (s. f.); Amazon Web Services (s. f.); Microsoft (s. f.) · 📚 Bibliografía

Demostración: un clúster de Spark en Google Cloud

Consola → Dataproc → Crear clúster. Lo que el sábado armamos a mano, aquí es un formulario. Mueva el número de trabajadores (simulación)

Nodos trabajadores: 2

Lo que calcula la consola

12 vCPU (CPU virtuales, 4 por máquina)

Tarifa de Dataproc: **0,010 USD × vCPU × hora = 0,12 USD/hora**

Más el costo de las máquinas virtuales (Compute Engine), que se cobra aparte.

Lo que se elige

La región (dónde están las máquinas), la imagen (versión de Hadoop y Spark) y **borrar el clúster si queda inactivo**.

💡 **En palabras simples:** Un **clúster** es un equipo de computadores: el **maestro** reparte el trabajo y los **trabajadores** lo hacen. Dataproc arma ese equipo en minutos y lo borra cuando ya no se necesita.

Hoy no lo creamos porque exige facturación. Escalar es mover un número, sin reinstalar nada. Para nuestro mes basta BigQuery, que reparte el trabajo por nosotros.

Fuentes: Google Cloud (s. f.), Dataproc y precios de Dataproc · 📚 Bibliografía

Taller 2A · El mes completo en BigQuery

9:30–10:30 · Colab divide y BigQuery carga. Yo lo hago con junio y ustedes con su mes

1. Zona de pruebas

En console.cloud.google.com/bigquery debe decir «Zona de pruebas» (*sandbox*). No pulse «Comenzar gratis».

2. Colab divide

En el cuaderno «dividir_mes_colab» escriben su mes, ejecutan las 5 celdas y descargan las partes, cada una de menos de 100 MB.

3. Cargar

Conjunto **tpd** en US (multirregión de Estados Unidos) → Crear tabla → Subir · Parquet. La parte 1 crea la tabla y las demás se suman con «Agrega a la tabla».

4. Comprobar

En Detalles, la «Cantidad de filas» debe ser igual a los viajes que dio Colab. Junio: 19.868.009.

Simulación de la carga de junio ▶ Cargar las 6 partes Tabla **tpd.viajes_2025_06**: **0** filas

Parte 1 · 3.311.335 filas · ≈88 MB | **Parte 2 · 3.311.335 filas · ≈88 MB** | **Parte 3 · 3.311.335 filas · ≈88 MB** | **Parte 4 · 3.311.335 filas · ≈88 MB** | **Parte 5 · 3.311.335 filas · ≈88 MB** | **Parte 6 · 3.311.334 filas · ≈88 MB**

💡 **En palabras simples: Parquet** es un archivo comprimido por columnas. **Conjunto de datos** es una carpeta de BigQuery. **Tabla** son los viajes en filas y columnas. Vamos a subir el mes en 6 pedazos y BigQuery los junta en una sola tabla.

¿Por qué partirlo? La consola acepta archivos de hasta 100 MB. Es la misma idea de HDFS: el archivo grande se guarda en bloques.

Fuentes: Google Cloud (s. f.), zona de pruebas y carga de Parquet; TLC (2025) · 📚 Bibliografía

Las 8 preguntas del Proyecto Final, en SQL

10:30–11:40 · Es el mismo cálculo con otra tecnología, y debe dar lo mismo al centavo. Carrera de la pregunta 1 con junio, a velocidad real ÷ 10

▶ Correr la pregunta 1 0,0 s

Hadoop MapReduce (31 oct)		—
Spark con CSV (31 oct)		—
Spark con Parquet (31 oct)		—
BigQuery (4 nov)		—

Las cuatro dan lo mismo: Uber 14.167.361 viajes y US$ 411.920.420,29; Lyft 5.700.648 viajes y US$ 145.003.586,84.

Cómo se trabaja

Copie la consulta del tutorial (ya trae su mes), mire el costo estimado, pulse Ejecutar y anote la duración y los bytes de «Información del trabajo».

Exactitud

El dinero se suma como NUMERIC (decimal exacto, sin errores de redondeo) y las millas con redondeo al par, igual que en Hadoop y Spark.

Verificación

Cada grupo compara sus 8 resultados con la clave de su mes que tiene el docente.

💡 **En palabras simples: SQL** es el idioma para preguntarle a la tabla: **SELECT** qué quiero ver, **FROM** de qué tabla, **WHERE** qué filas, **GROUP BY** cómo agrupar. No hay que memorizarlo: el tutorial trae las 8 consultas listas.

BigQuery viene de Dremel (Google, 2010): guarda por columnas y pone miles de máquinas a leer en paralelo.

Fuentes: Melnik et al. (2010); medidas de los talleres del 31 de octubre y del 4 de noviembre · 📚 Bibliografía

BigQuery cobra por lo que lee

11:40–12:00 · Marque las columnas de su consulta y vea lo que diría el validador. Son bytes reales de junio por columna

SELECT * (las 25) | **Pregunta 1 (2 columnas)** | **+ LIMIT 10** | **Limpiar**

- [ ] hvfhs_license_num
- [ ] dispatching_base_num
- [ ] originating_base_num
- [ ] request_datetime
- [ ] on_scene_datetime
- [ ] pickup_datetime
- [ ] dropoff_datetime
- [ ] PULocationID
- [ ] DOLocationID
- [ ] trip_miles
- [ ] trip_time
- [ ] base_passenger_fare
- [ ] tolls
- [ ] bcf
- [ ] sales_tax
- [ ] congestion_surcharge
- [ ] airport_fee
- [ ] tips
- [ ] driver_pay
- [ ] shared_request_flag
- [ ] shared_match_flag
- [ ] access_a_ride_flag
- [ ] wav_request_flag
- [ ] wav_match_flag
- [ ] cbd_congestion_fee

Esta consulta procesará

0 MB

Sin LIMIT

Del terabyte gratis del mes

0,00 % por consulta

Consultas así por mes

—

antes de pagar (1 TB = 1.048.576 MiB)

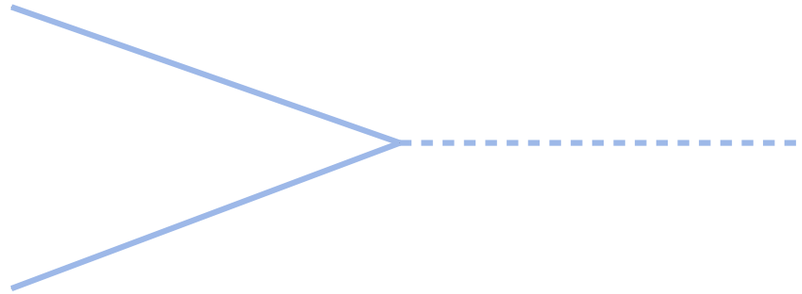
💡 **En palabras simples:** BigQuery cobra **por lo que lee, no por lo que muestra**: es como pagar por cada página que se lee del libro, no por la respuesta. Leer menos columnas = pagar menos.

LIMIT no ahorra: devuelve 10 filas, pero lee todas las columnas elegidas. Lo que sí ahorra es escribir solo las columnas necesarias. Es la optimización de costos que pide la rúbrica.

Fuentes: Google Cloud (s. f.), precios de BigQuery; bytes por columna de junio calculados por el docente (cuadran con el validador: 3,2 GB y 303 MB) · Bibliografía

El modelo en estrella: resumir en la nube, analizar en Power BI

1:00–1:20 · BigQuery hace el trabajo pesado con un GROUP BY (agrupar) y Power BI recibe solo lo necesario



Las líneas son relaciones: zona_id une hechos con zonas

Simulación: resumir junio

▶ GROUP BY Viajes uno por uno

19.868.009

filas que llegan a Power BI

25 s

crear las 3 tablas en BigQuery

15 medidas

en DAX (Data Analysis Expressions)

💡 **En palabras simples: Hechos** = lo que pasó y se cuenta (viajes, dinero). **Dimensiones** = por dónde se filtra (zona, fecha, empresa). La **relación** es la columna que las une, como el código de un producto en una factura.

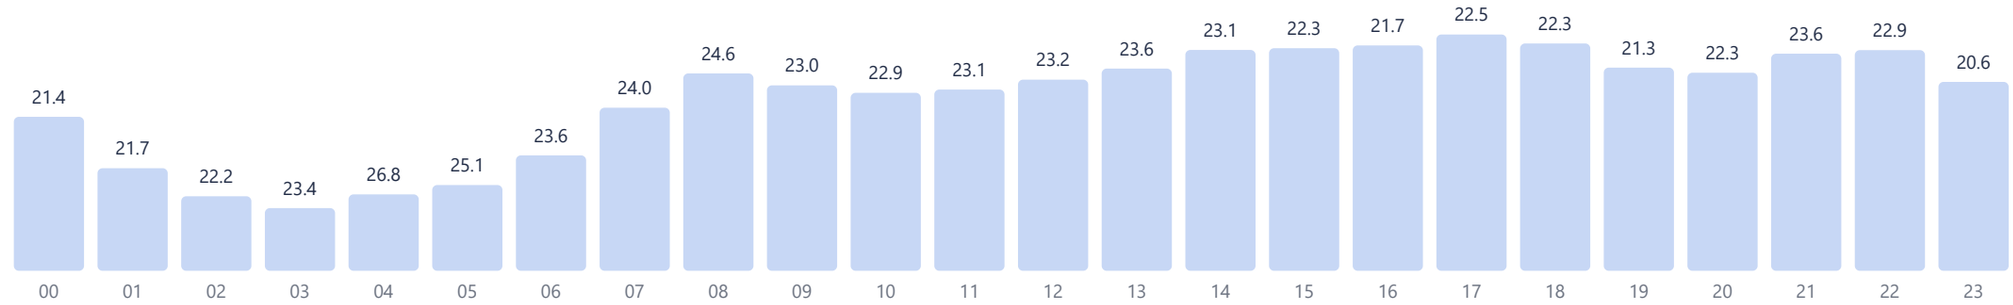
Una tabla de hechos en el centro y sus dimensiones alrededor: así Power BI filtra rápido y las cifras cuadran.

Fuentes: Kimball y Ross (2013); Microsoft (s. f.), esquema de estrella · 📚 Bibliografía

La trampa del promedio de promedios

1:20–1:35 · ¿Qué parte de la tarifa se queda la plataforma en junio? Dos formas de calcularlo con los mismos datos

Promedio de los 24 porcentajes | **Suma ÷ suma (la medida correcta)**



Hora · barras: tarifa base de esa hora (el peso real) · número: % de plataforma de la hora

Promedio de promedios

22,96 %

Cada hora pesa igual, tenga 300 mil o 1,1 millones de viajes

Suma ÷ suma

22,81 %

US$ 127,0 millones ÷ US$ 556,9 millones de tarifa: la cifra de la clave

La medida en DAX

```
% Plataforma =
DIVIDE(SUM(hechos_viajes[plataforma]),
       SUM(hechos_viajes[tarifa_base]))
```

💡 **En palabras simples:** Si una hora tuvo 300 mil viajes y otra 1,1 millones, **no pesan igual**. Por eso primero se suma todo y se divide una sola vez al final.

Una diferencia de 0,15 puntos sobre US$ 557 millones equivale a unos US$ 830 mil mal reportados a la gerencia. Por eso toda razón se mide como suma ÷ suma.

Fuentes: TLC (2025), pregunta 1 de junio; Microsoft (s. f.), medidas DAX · 📚 Bibliografía

Power BI conectado a BigQuery

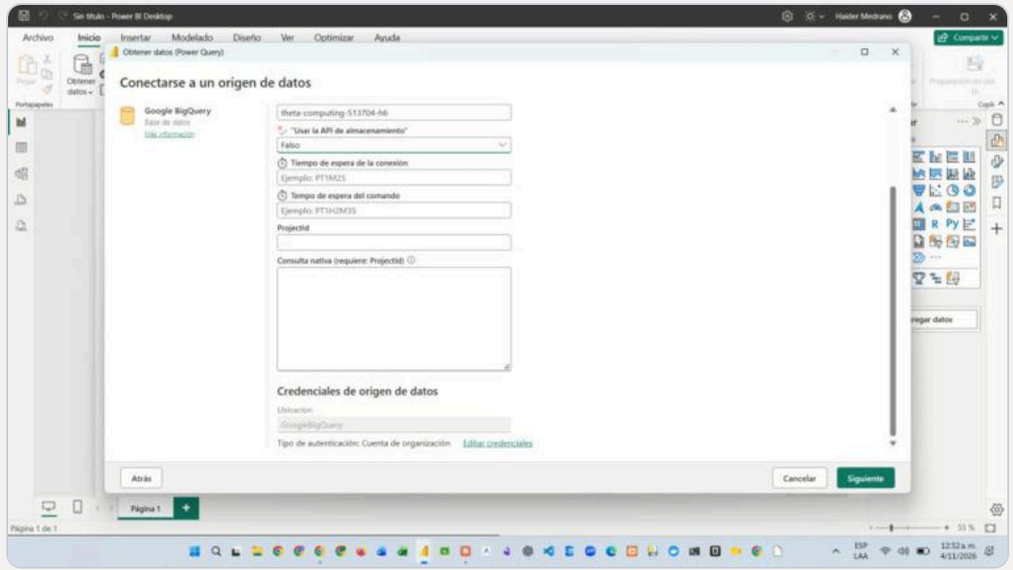
1:35–2:05 · Los datos viajan resumidos por el conector y se guardan en el archivo .pbix (modo Importar)

BigQuery
357.040 + 265 + 10 filas

Conector
OAuth 2.0

Power BI Desktop
modelo en memoria

Opción	Valor	Por qué
Ruta	Obtener datos → Más → pestaña **Nuevo** → Google BigQuery	la pestaña «Inicio» se queda cargando
Modo	Importar	tablero rápido, sin gastar consultas
ID del proyecto de facturación	el ID de su proyecto	la zona de pruebas lo necesita
Usar la API de almacenamiento	Falso	falla sin facturación
Autenticación	OAuth 2.0 → Iniciar sesión	la misma cuenta de BigQuery



Captura real del 4 de noviembre: opciones avanzadas

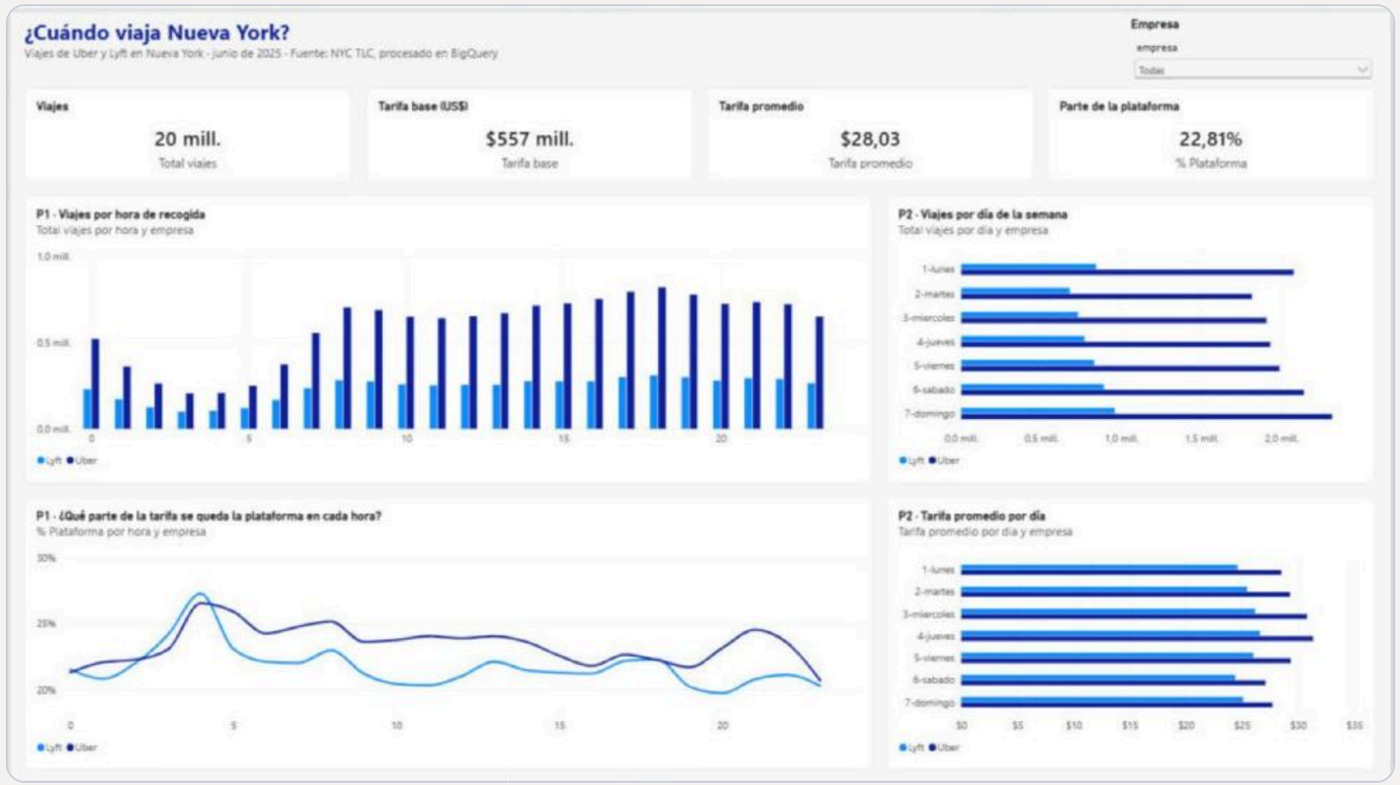
💡 **En palabras simples: Conector** = el puente entre Power BI y BigQuery. **Importar** = traer una copia de los datos al archivo .pbix. **OAuth** = iniciar sesión con Google sin darle su contraseña a Power BI.

Si el navegador no muestra las tablas nuevas: Transformar datos → Consulta en blanco, con la fórmula del tutorial (paso 2.3).

Fuentes: Microsoft (s. f.), conector de Google BigQuery · Bibliografía

Taller 2B · Tres páginas para la gerencia

2:05–3:35 · Así queda junio. Pulse cada página (capturas reales de Power BI, 4 de noviembre)



1 · Demanda | 2 · Dinero y propinas | 3 · Ciudad

1 · Demanda

¿Cuándo viaja Nueva York? Viajes por hora (P1) y por día (P2), % de plataforma por hora y tarifa promedio por día.

Plataforma
22,81 % de la tarifa

Con propina
18,89 % de los viajes

Velocidad
15,13 mph (24,3 km/h)

LaGuardia
la zona que más deja: US$ 8,07 M

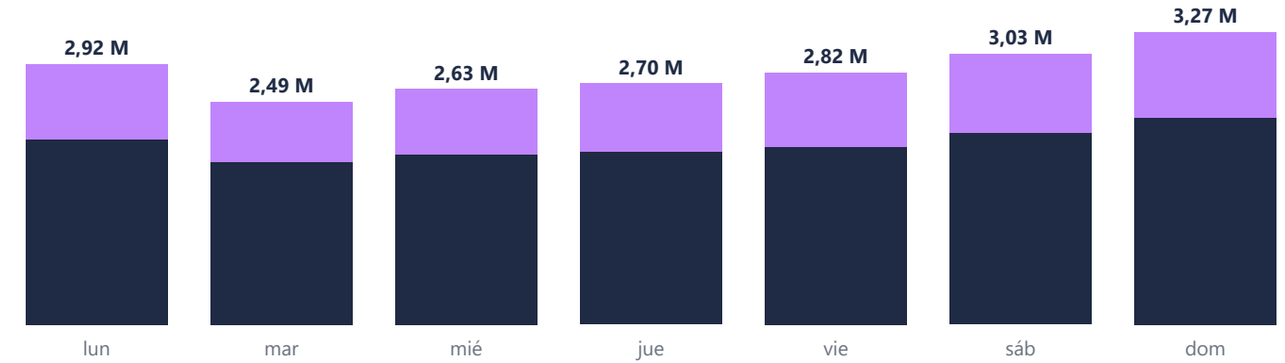
💡 **En palabras simples:** Una **medida DAX** es una fórmula que calcula un número (total de viajes, % de plataforma). Un **visual** es cada gráfico de la página. Un **dashboard** es la página completa que ve la gerencia.

Cada título lleva su pregunta (P1 a P8) y cada página termina en una conclusión con las cifras de su mes.

Así responde un filtro de empresa

Viajes reales de junio por día de la semana (pregunta 2). El filtro (segmentador) recalcula todas las medidas a la vez

Ambas | Uber | Lyft



Azul oscuro: Uber · morado: Lyft

Total viajes
19.868.009

Día con más viajes
domingo · 3.274.200

Tarifa promedio más alta
US$ 31,34 · Uber, jueves

💡 **En palabras simples:** El **segmentador** es el botón de filtro del tablero. Al elegir Uber, todas las medidas se recalculan solo para Uber, al instante.

Así funcionan las medidas: no guardan un número, lo recalculan con cada filtro. Por eso el tablero responde en el instante.

Fuentes: TLC (2025), pregunta 2 de junio · 📚 Bibliografía

Cierre del día

Lo que debe tener cada grupo antes de irse

✓ Su mes en BigQuery
Las filas cargadas son iguales a los viajes que dio Colab, y está la tabla zonas.

✓ Las 8 respuestas
Iguales a la clave, con su duración y sus bytes anotados.

✓ El modelo en Power BI
Las 3 tablas cargadas y la relación zona_id.

✓ Página 1 del dashboard
Demanda: viajes por hora y por día, y el % de plataforma.

Lo que sigue
Las páginas 2 y 3 del dashboard con el tutorial 2B. El cronograma de los próximos encuentros se confirma por el grupo del curso.

Guarden
El .pbix con el nombre Dashboard_TLC_su-mes. No borren las tablas de BigQuery: duran 60 días.

¿Quedó todo bien? Corran el verificador
En el tutorial del Taller 2A, sección **«Al terminar · ¿quedó todo bien?»**: copien la consulta, péguenla en BigQuery y pulsen Ejecutar. Cada fila responde ✓ o dice **qué falta y en qué paso**.

Hoy el mismo mes pasó de 3 minutos en Hadoop a un cuarto de segundo en BigQuery, y llegó a un tablero para la gerencia.

Bibliografía

Las fuentes de cada concepto de la sesión (normas APA, 7.ª ed.). Cada enlace abre la fuente en una pestaña nueva

La nube

Mell, P., & Grance, T. (2011). *The NIST definition of cloud computing* (NIST Special Publication 800-145). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-145

Armbrust, M., Fox, A., Griffith, R., Joseph, A. D., Katz, R., Konwinski, A., Lee, G., Patterson, D., Rabkin, A., Stoica, I., & Zaharia, M. (2010). A view of cloud computing. *Communications of the ACM, 53*(4), 50–58. https://doi.org/10.1145/1721654.1721672

Google Cloud. (s. f.). *Dataproc documentation*. https://cloud.google.com/dataproc/docs

Amazon Web Services. (s. f.). *Amazon EMR*. https://aws.amazon.com/emr/

Microsoft. (s. f.). *Azure HDInsight documentation*. Microsoft Learn. https://learn.microsoft.com/en-us/azure/hdinsight/

Universidad Internacional de La Rioja. (2026). *Ingeniería para el procesado masivo de datos*, temas 8 a 10: Cloud computing I, II y III [Material de curso]. Máster en Análisis y Visualización de Datos Masivos.

Google Cloud. (s. f.). *Dataproc pricing*. https://cloud.google.com/dataproc/pricing

Devicons. (s. f.). *Devicon* (v2.16.0) [Logos; licencia MIT]. https://github.com/devicons/devicon

BigQuery

Melnik, S., Gubarev, A., Long, J. J., Romer, G., Shivakumar, S., Tolton, M., & Vassilakis, T. (2010). Dremel: Interactive analysis of web-scale datasets. *Proceedings of the VLDB Endowment, 3*(1–2), 330–339. https://doi.org/10.14778/1920841.1920886

Google Cloud. (s. f.). *Enable the BigQuery sandbox*. BigQuery documentation. https://cloud.google.com/bigquery/docs/sandbox

Google Cloud. (s. f.). *BigQuery pricing*. https://cloud.google.com/bigquery/pricing

Google Cloud. (s. f.). *Loading Parquet data*. BigQuery documentation. https://cloud.google.com/bigquery/docs/loading-data-cloud-storage-parquet

El caso

New York City Taxi and Limousine Commission. (2025). *TLC trip record data: High volume for-hire vehicle trip records, 2025* [Conjunto de datos]. https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page

Power BI y modelado

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3.ª ed.). Wiley.

Microsoft. (s. f.). *Understand star schema and the importance for Power BI*. Microsoft Learn. https://learn.microsoft.com/en-us/power-bi/guidance/star-schema

Microsoft. (s. f.). *Connect to a Google BigQuery database in Power BI Desktop*. Microsoft Learn. https://learn.microsoft.com/en-us/power-bi/connect-data/desktop-connect-bigquery

Seguridad y normativa

Google Cloud. (s. f.). *Access control with IAM*. BigQuery documentation. https://cloud.google.com/bigquery/docs/access-control

Microsoft. (s. f.). *DIVIDE function (DAX)*. Microsoft Learn. https://learn.microsoft.com/en-us/dax/divide-function-dax