TECNOLOGÍAS DE PROCESAMIENTO DE DATOS · ESPECIALIZACIÓN EN ANALÍTICA DE DATOS · UNIVERSIDAD RAFAEL NÚÑEZ

Proyecto Final · Un mes de Nueva York en la nube

Versión del 4 de noviembre de 2026 (reemplaza la del 31 de octubre) · Entrega y sustentación: la Sesión 6 · Docente: Heyder Medrano Olier

1. El reto

La gerencia de una plataforma de movilidad pregunta

Con los viajes de Uber y Lyft en Nueva York, la gerencia quiere un tablero que responda 8 preguntas, procesado en la nube y con un costo controlado. Cada grupo trabaja **un mes distinto de 2025**: así nadie copia cifras y al final comparamos meses.

Grupo	Mes de 2025	Qué lo hace interesante
Docente (demostración en clase)	Junio	ya verificado con Hadoop, Spark y BigQuery: 19.868.009 viajes
Grupo 1	**Enero**	el 5 de enero empezó el cargo de congestión de Manhattan; invierno
Grupo 2	**Abril**	primavera, un mes «normal»
Grupo 3	**Septiembre**	regreso a clases y oficinas
Grupo 4	**Diciembre**	fiestas: el mes más pesado (22,1 millones de viajes)

Las ocho preguntas

	Pregunta de la gerencia
P1	¿A qué horas hay más viajes y qué parte de la tarifa se queda la plataforma en cada hora?
P2	¿Cómo cambian los viajes y la tarifa promedio según el día de la semana y la empresa?
P3	¿Dónde y con qué empresa se dejan más propinas?
P4	¿Cuánto mueven los aeropuertos (Newark, JFK y LaGuardia), desde y hacia ellos?
P5	¿Cuánto se le paga al conductor por milla, según el borough y la empresa?
P6	¿A qué horas es más lento moverse por la ciudad?

P7	¿Qué zonas de recogida le dejan más dinero a la plataforma?
P8	¿Cuánto recauda el cargo de congestión de Manhattan y a qué horas?

2. Cómo se hace

Con los talleres

Taller 2A (Sesión 3): dividir su mes en Colab, cargarlo en BigQuery y resolver las 8 preguntas en SQL, midiendo tiempo y costo.
Taller 2B (Sesión 4): tablas resumen en BigQuery, modelo y medidas DAX en Power BI y el dashboard de 3 páginas.
Las mediciones de Hadoop y Spark son las que tomaron en los talleres 1A y 1B del 31 de octubre: no hay que repetirlas.

> **Por qué:** comparar tecnologías exige el mismo cálculo con cifras idénticas: Hadoop, Spark y BigQuery dieron lo mismo al centavo con junio; con su mes, la referencia es la clave del docente.

3. Lo que entrega el grupo

Una sola entrega, en la Sesión 6

Entregable	Qué debe tener
1. Informe técnico (6 a 8 páginas, PDF)	**a) Arquitectura:** de la TLC a Colab (división), a BigQuery (tabla nativa), a las tablas resumen y a Power BI; por qué cada pieza. **b) Configuración:** conjunto de datos, ubicación, formato, preferencia de escritura y conexión de Power BI, con su justificación (como en los tutoriales). **c) Verificación:** las 8 respuestas de su mes, iguales a la clave al centavo; filas cargadas = viajes del mes. **d) Rendimiento y costo:** tabla de tiempos de la misma pregunta en Hadoop y Spark (taller del 31, junio) y en BigQuery (junio y su mes); bytes procesados por consulta; la optimización de costos (columnas, LIMIT); cuello de botella de cada tecnología. **e) Selección de nube:** la matriz del análisis de caso (AWS, Google Cloud, Azure) aplicada a su empresa. **f) Conclusiones para la gerencia:** una por página del dashboard, con cifras de su mes, y qué cambiaría con un año de datos (12 veces más).
2. Dashboard en Power BI (.pbix)	Las 3 páginas del Taller 2B con los datos de su mes, títulos con la pregunta (P1 a P8), filtro de empresa y tarjetas que coinciden con la clave.

3. Sustentación (15 minutos)	Sesión 6. Hablan todos los integrantes; se muestra el dashboard en vivo y una consulta en BigQuery con su costo; 5 minutos de preguntas.

4. Cómo se evalúa

Tres criterios con el mismo peso

Criterio (contenido programático)	Excelente	Aceptable	Insuficiente
Configuración del sistema (1/3)	Entorno en la nube configurado y justificado opción por opción; Power BI conectado; explica qué haría distinto con facturación (Cloud Storage, Dataproc).	Entorno funcionando, con justificación parcial.	Pasos copiados sin explicar, o el entorno no funciona.
Integración de datos (1/3)	Mes completo cargado (filas = viajes), 8 respuestas iguales a la clave al centavo, zonas unidas y dashboard sin pérdidas.	Respuestas correctas con alguna diferencia explicada o una pregunta incompleta.	Cifras que no coinciden o datos incompletos.
Rendimiento y costos (1/3)	Compara Hadoop, Spark y BigQuery con mediciones propias, identifica el cuello de botella de cada una y cuantifica el ahorro de la optimización de costos.	Mide tiempos y bytes, pero no los interpreta.	Sin mediciones o sin fuente.

La sustentación cubre también la «Simulación: procesamiento de datos masivos en la nube» (configuración del entorno, optimización de costos y análisis de resultados) y el análisis de casos (selección de tecnologías).

5. Calendario

Fechas

Fecha	Qué pasa
Sesión 3	Taller 2A: cada grupo divide su mes en Colab, lo carga en BigQuery y resuelve las 8 preguntas (el docente lo hace primero con junio).
Sesión 4	Taller 2B: dashboard en Power BI con su mes. Análisis de casos: selección de nube.

Entre las sesiones 4 y 6	Cada grupo termina el dashboard y escribe el informe. Las tablas de la zona de pruebas duran 60 días: no hay que volver a cargarlas.
Sesión 5	Dataproc: el clúster administrado (laboratorio de Google Skills explicado y demostración en la consola), Unidad 3 (optimización con evidencia) y asesoría de los proyectos: cada grupo muestra su avance.
Sesión 6	Entrega del informe y del .pbix, y sustentación (15 minutos por grupo).